

第二章 线性方程组的敏度分析与 消去法的舍入误差分析

第一节 向量范数和矩阵范数

张振宇

上海财经大学 数学学院

向量范数的定义

定义 2.1.1

一个从 $\mathbb{R}^n$ 到 $\mathbb{R}$ 的非负函数 $\|\cdot\|$ 叫做 $\mathbb{R}^n$ 上的**向量范数**，如果它满足：

- (1) 正定性： $\forall \mathbf{x} \in \mathbb{R}^n$, 有 $\|\mathbf{x}\| \geq 0$, 而且 $\|\mathbf{x}\| = 0$ 当且仅当 $\mathbf{x} = \mathbf{0}$;
- (2) 齐次性： $\forall \mathbf{x} \in \mathbb{R}^n$ 和 $\alpha \in \mathbb{R}$, 有 $\|\alpha \mathbf{x}\| = |\alpha| \|\mathbf{x}\|$;
- (3) 三角不等式： $\forall \mathbf{x}, \mathbf{y} \in \mathbb{R}^n$, 有 $\|\mathbf{x} + \mathbf{y}\| \leq \|\mathbf{x}\| + \|\mathbf{y}\|$.

向量范数的定义满足范数公理。从定义中的(2), (3)可推出： $\forall \mathbf{x}, \mathbf{y} \in \mathbb{R}^n$

$$\left| \|\mathbf{x}\| - \|\mathbf{y}\| \right| \leq \|\mathbf{x} - \mathbf{y}\| \leq \max_{1 \leq i \leq n} \|\mathbf{e}_i\| \sum_{i=1}^n |x_i - y_i|.$$

即当 $\mathbf{y} \rightarrow \mathbf{x}$ 时, $f(\mathbf{y}) \rightarrow f(\mathbf{x})$, 这里 $f(\mathbf{x}) = \|\mathbf{x}\|$. (**向量范数连续性**)

向量范数连续性证明

$$\forall \mathbf{x}, \mathbf{y} \in \mathbb{R}^n,$$

$$\because \mathbf{x} = (\mathbf{x} - \mathbf{y}) + \mathbf{y}, \quad \mathbf{y} = (\mathbf{y} - \mathbf{x}) + \mathbf{x},$$

由向量范数定义(3),

$$\|\mathbf{x}\| \leq \|\mathbf{x} - \mathbf{y}\| + \|\mathbf{y}\|, \quad \|\mathbf{y}\| \leq \|\mathbf{y} - \mathbf{x}\| + \|\mathbf{x}\|,$$

即

$$-\|\mathbf{x} - \mathbf{y}\| = -\|\mathbf{y} - \mathbf{x}\| \leq \|\mathbf{x}\| - \|\mathbf{y}\| \leq \|\mathbf{x} - \mathbf{y}\| \Leftrightarrow \left| \|\mathbf{x}\| - \|\mathbf{y}\| \right| \leq \|\mathbf{x} - \mathbf{y}\|.$$

另一方面, 由向量范数定义(2)和(3), 有

$$\begin{aligned} \mathbf{x} - \mathbf{y} &= (x_1 - y_1)\mathbf{e}_1 + \cdots + (x_n - y_n)\mathbf{e}_n \\ \Leftrightarrow \|\mathbf{x} - \mathbf{y}\| &\leq \sum_{i=1}^n |x_i - y_i| \|\mathbf{e}_i\| \leq \sum_{i=1}^n \left(\max_{1 \leq k \leq n} \|\mathbf{e}_k\| \right) |x_i - y_i| \end{aligned}$$

常用向量范数

常用的

$$\|\mathbf{x}\|_p = (|x_1|^p + \cdots + |x_n|^p)^{\frac{1}{p}}, \quad p \geq 1,$$

称为 p 范数(也叫Hölder范数)。其中, 最重要的是 $p = 1, 2, \infty$ 时的范数:

$$\|\mathbf{x}\|_1 = |x_1| + \cdots + |x_n|,$$

$$\|\mathbf{x}\|_2 = (|x_1|^2 + \cdots + |x_n|^2)^{\frac{1}{2}} = \sqrt{\mathbf{x}^T \mathbf{x}},$$

$$\|\mathbf{x}\|_\infty = \max\{|x_i| : i = 1, \cdots, n\}.$$

它们被称为1-范数, 2-范数和 ∞ -范数。满足 $\|\mathbf{x}\| = 1$ 的向量 $\mathbf{x}$ 被称为单位向量。(想想, 在二维平面中, $\|\mathbf{x}\|_1 = 1$, $\|\mathbf{x}\|_2 = 1$, $\|\mathbf{x}\|_\infty = 1$ 各是怎样的图形?)

Hölder不等式

$\|\cdot\|_2$ 的三角不等式性质证明需要用到Hölder不等式

$$|\mathbf{x}^T \mathbf{y}| \leq \|\mathbf{x}\|_p \|\mathbf{y}\|_q, \quad \frac{1}{p} + \frac{1}{q} = 1, \mathbf{x}, \mathbf{y} \in \mathbb{R}^n$$

的特殊情形——Cauchy-Schwartz不等式

$$|\mathbf{x}^T \mathbf{y}| \leq \|\mathbf{x}\|_2 \|\mathbf{y}\|_2.$$

2-范数三角不等式的证明

$$\begin{aligned}\|\boldsymbol{x} + \boldsymbol{y}\|_2^2 &= (\boldsymbol{x} + \boldsymbol{y})^T (\boldsymbol{x} + \boldsymbol{y}) \\&= \|\boldsymbol{x}\|_2^2 + \boldsymbol{x}^T \boldsymbol{y} + \boldsymbol{y}^T \boldsymbol{x} + \|\boldsymbol{y}\|_2^2 \\&\leq \|\boldsymbol{x}\|_2^2 + 2\|\boldsymbol{x}\|_2 \|\boldsymbol{y}\|_2 + \|\boldsymbol{y}\|_2^2 \\&= (\|\boldsymbol{x}\|_2 + \|\boldsymbol{y}\|_2)^2.\end{aligned}$$

向量范数的等价性

虽然范数定义各不相同，但在以下定理的意义下是等价的。

定理2.1.1 范数等价定理

设 $\|\cdot\|_\alpha$ 和 $\|\cdot\|_\beta$ 是 $\mathbb{R}^n$ 上的任意两个范数，则 $\exists c_1, c_2 > 0$ ，使得 $\forall \mathbf{x} \in \mathbb{R}^n$ ，有

$$c_1 \|\mathbf{x}\|_\alpha \leq \|\mathbf{x}\|_\beta \leq c_2 \|\mathbf{x}\|_\alpha.$$

证明略，可参考《矩阵扰动分析》（孙继广，1987）。

例如：

$$\|\mathbf{x}\|_2 \leq \|\mathbf{x}\|_1 \leq \sqrt{n} \|\mathbf{x}\|_2,$$

$$\|\mathbf{x}\|_\infty \leq \|\mathbf{x}\|_2 \leq \sqrt{n} \|\mathbf{x}\|_\infty,$$

$$\|\mathbf{x}\|_\infty \leq \|\mathbf{x}\|_1 \leq n \|\mathbf{x}\|_\infty.$$

向量序列依范数收敛

定理2.1.2 向量序列依范数收敛等价于其分量收敛定理

设 $\boldsymbol{x}_k \in \mathbb{R}^n$, 则

$$\lim_{k \rightarrow \infty} \|\boldsymbol{x}_k - \boldsymbol{x}\| = 0 \Leftrightarrow \lim_{k \rightarrow \infty} |x_i^{(k)} - x_i| = 0, \quad i = 1, \dots, n.$$

若向量序列 $\{\boldsymbol{x}_k\}$ 依某种范数收敛到 $\boldsymbol{x}$, 那么由定理2.1.1 (即范数等价定理) 可知, 该向量按任何与其等价的范数, 都收敛到 $\boldsymbol{x}$.

矩阵范数

定义2.1.2 矩阵范数定义

一个从 $\mathbb{R}^{n \times n}$ 到 $\mathbb{R}$ 的非负函数 $\|\cdot\|$ 叫做 $\mathbb{R}^{n \times n}$ 上的矩阵函数，如果它满足：

- ① 正定性： $\forall A \in \mathbb{R}^{n \times n}$ ，有 $\|A\| \geq 0$ ，而且 $\|A\| = 0$ 当且仅当 $A = 0$ ；
- ② 齐次性： $\forall A \in \mathbb{R}^{n \times n}$ 和 $\alpha \in \mathbb{R}$ ，有 $\|\alpha A\| = |\alpha| \|A\|$ ；
- ③ 三角不等式： $\forall A, B \in \mathbb{R}^{n \times n}$ ，有 $\|A + B\| \leq \|A\| + \|B\|$ ；
- ④ 相容性： $\forall A, B \in \mathbb{R}^{n \times n}$ ，有 $\|AB\| \leq \|A\| \|B\|$ 。

矩阵范数的等价性和矩阵序列依范数收敛

$\mathbb{R}^{n \times n}$ 中的矩阵范数可以看成 $\mathbb{R}^{n^2}$ 中的向量范数（把矩阵拉直）。所以矩阵范数具备向量范数的性质，比如：

- $\mathbb{R}^{n \times n}$ 中任两个矩阵范数是等价的；
- 矩阵序列依范数收敛等价于其元素收敛，即

$$\lim_{k \rightarrow \infty} \|A_k - A\| = 0 \Leftrightarrow \lim_{k \rightarrow \infty} \left| a_{ij}^{(k)} - a_{ij} \right| = 0, \quad i, j = 1, \dots, n,$$

其中 $A_k = \begin{pmatrix} a_{ij}^{(k)} \end{pmatrix} \mathbb{R}^{n \times n}$.

矩阵范数与向量范数的相容性

定义2.1.3 矩阵范数与向量范数的相容性定义

若矩阵范数 $\|\cdot\|_M$ 和向量范数 $\|\cdot\|_v$ 满足

$$\|A\mathbf{x}\|_v \leq \|A\|_M \|\mathbf{x}\|_v, \quad A \in \mathbb{R}^{n \times n}, \mathbf{x} \in \mathbb{R}^n,$$

则称矩阵范数 $\|\cdot\|_M$ 与向量范数 $\|\cdot\|_v$ 是相容的。

注：本课程中若没有特别说明，凡同时涉及向量范数和矩阵范数的，都假定它们是相容的。

由向量范数诱导的矩阵范数

对于任意给定的向量范数，总可以构造一个与其相容的矩阵范数。

定理 2.1.3 矩阵范数与向量范数相容定理

设 $\|\cdot\|$ 是 $\mathbb{R}^n$ 上的一个向量范数。若定义

$$\|A\| = \max_{\|x\|=1} \|Ax\|, \quad A \in \mathbb{R}^{n \times n},$$

则 $\|\cdot\|$ 是 $\mathbb{R}^{n \times n}$ 上的一个矩阵范数。

定理中的矩阵范数 $\|\cdot\|$ 称为是由向量范数 $\|\cdot\|$ 诱导的矩阵范数（算子范数）。

定理2.1.3的证明

(1) 首先证明：向量范数 $\|\cdot\|$ 在 $\mathcal{D} = \{\mathbf{x} \in \mathbb{R}^n : \|\mathbf{x}\| = 1\}$ 中存在最大值。
 $\because \mathcal{D} \subset \mathbb{R}^n$ 是有界闭集，而向量范数 $\|\cdot\|$ 是 $\mathbb{R}^n$ 的连续函数，
 $\therefore \exists \mathbf{x}_0 \in \mathcal{D}$, s.t. $\|A\mathbf{x}_0\| = \max_{\mathbf{x} \in \mathcal{D}} \|A\mathbf{x}\|$.

(2) 其次证明 $\|\cdot\|$ 与向量范数 $\|\cdot\|$ 相容。
 $\forall \mathbf{x} \in \mathbb{R}^n, \mathbf{x} \neq \mathbf{0}$,

$$\frac{\|A\mathbf{x}\|}{\|\mathbf{x}\|} = \left\| A \frac{\mathbf{x}}{\|\mathbf{x}\|} \right\| \leq \max_{\|\mathbf{x}\|=1} \|A\mathbf{x}\| = \|A\|.$$

即

$$\|A\mathbf{x}\| \leq \|A\| \|\mathbf{x}\|. \quad \mathbf{x} \in \mathbb{R}^n.$$

定理2.1.3的证明.

(3) 最后证明 $\forall A, B \in \mathbb{R}^{n \times n}$, $\|\cdot\|$ 满足矩阵范数的四条性质:

- 正定性。设 $A \neq 0$, 不妨设 A 的第 i 列 $A\mathbf{e}_i$ ($1 \leq i \leq n$)非零, 则

$$0 < \|A\mathbf{e}_i\| \leq \|A\| \|\mathbf{e}_i\| \Leftrightarrow \|A\| > 0.$$

- 齐次性。任取 $\alpha \in \mathbb{R}$, 有

$$\|\alpha A\| = \max_{\|\mathbf{x}\|=1} \|\alpha A\mathbf{x}\| = |\alpha| \max_{\|\mathbf{x}\|=1} \|A\mathbf{x}\| = |\alpha| \|A\|.$$

- 三角不等式。设 $\mathbf{x}$ 满足 $\|\mathbf{x}\| = 1$, 使得 $\|(A+B)\mathbf{x}\| = \|A+B\|$, 则由向量范数的三角不等式和与向量范数的相容性, 有

$$\begin{aligned} \|A+B\| &= \|(A+B)\mathbf{x}\| \leq \|A\mathbf{x}\| + \|B\mathbf{x}\| \\ &\leq \|A\| \|\mathbf{x}\| + \|B\| \|\mathbf{x}\| = \|A\| + \|B\| \end{aligned}$$

定理2.1.3的证明..

- 相容性。设 $\mathbf{x} \in \mathbb{R}^n$ 满足 $\|\mathbf{x}\| = 1$, 使得 $\|AB\mathbf{x}\| = \|AB\|$, 则

$$\|AB\| = \|AB\mathbf{x}\| \leq \|A\| \|B\mathbf{x}\| \leq \|A\| \|B\| \|\mathbf{x}\| = \|A\| \|B\|.$$

上面的讨论中, 我们用 $\|\cdot\|$ 来记矩阵范数, 在后面的内容中, 为了简单起见, 我们仍使用 $\|\cdot\|$ 来记矩阵范数。根据上下文, 应该不会引起混淆。

一般, 从 $\mathbb{R}^n$ 的 p -范数诱导的 $\mathbb{R}^{n \times n}$ 上的矩阵范数为

$$\|A\|_p = \max_{\|\mathbf{x}\|_p=1} \|A\mathbf{x}\|_p, \quad A \in \mathbb{R}^{n \times n}.$$

列和范数、行和范数和谱范数

定理2.1.4 常用矩阵范数定义

设 $A = (a_{ij}) \in \mathbb{R}^{n \times n}$, 则

$$\|A\|_1 = \max_{1 \leq j \leq n} \sum_{i=1}^n |a_{ij}|, \quad \text{列和范数}$$

$$\|A\|_\infty = \max_{1 \leq i \leq n} \sum_{j=1}^n |a_{ij}|, \quad \text{行和范数}$$

$$\|A\|_2 = \sqrt{\lambda_{\max}(A^T A)}, \quad \text{谱范数}$$

其中 $\lambda_{\max}(A^T A)$ 表示 $A^T A$ 的最大特征值。由于 $A = 0$ 是平凡情况，以下对于上述三式的证明都在 $A \neq 0$ 的前提下。

矩阵1-范数是列和的证明

记 $A = [\mathbf{a}_1, \cdots, \mathbf{a}_n]$, 且记 $\delta = \|\mathbf{a}_{j_0}\|_1 = \max_{1 \leq j \leq n} \|\mathbf{a}_j\|_1$, 即 A 的第 j_0 列具有最大的1-范

数 (向量范数)。那么, $\forall \mathbf{x}, \|\mathbf{x}\|_1 = \sum_{i=1}^n |x_i| = 1$, 有

$$\begin{aligned}\|A\mathbf{x}\|_1 &= \left\| \sum_{j=1}^n x_j \mathbf{a}_j \right\|_1 \leq \sum_{j=1}^n |x_j| \|\mathbf{a}_j\|_1 \\ &\leq \left(\sum_{j=1}^n |x_j| \right) \max_{1 \leq j \leq n} \|\mathbf{a}_j\|_1 = \|\mathbf{a}_{j_0}\|_1 = \delta.\end{aligned}$$

若特别取 $\mathbf{x} = \mathbf{e}_{j_0}$, 则 $\|\mathbf{e}_{j_0}\|_1 = 1$, 而且 $\|A\mathbf{e}_{j_0}\|_1 = \|\mathbf{a}_{j_0}\|_1 = \delta$. 因此

$$\|A\|_1 = \max_{\|\mathbf{x}\|_1=1} \|A\mathbf{x}\|_1 = \delta = \max_{1 \leq j \leq n} \|\mathbf{a}_j\|_1 = \max_{1 \leq j \leq n} \sum_{i=1}^n |a_{ij}|.$$

矩阵 ∞ -范数是行和的证明

$$\forall \mathbf{x} \in \mathbb{R}^n, \|\mathbf{x}\|_{\infty} = \max_{1 \leq i \leq n} |x_i| = 1$$

$$\|A\mathbf{x}\|_{\infty} = \max_{1 \leq i \leq n} \left| \sum_{j=1}^n a_{ij} x_j \right| \leq \max_{1 \leq i \leq n} \sum_{j=1}^n |a_{ij}| |x_j| \leq \max_{1 \leq i \leq n} \sum_{j=1}^n |a_{ij}| \stackrel{\text{def}}{=} \eta.$$

若 A 的第 i_0 行1-范数最大, 即 $\eta = \sum_{j=1}^n |a_{i_0 j}|$, 令 $\tilde{\mathbf{x}} = [\text{sgn}(a_{i_0 1}), \dots, \text{sgn}(a_{i_0 n})]^T$, 则
由 $A \neq 0 \Rightarrow \|\tilde{\mathbf{x}}\|_{\infty} = 1$, 且 $\|A\tilde{\mathbf{x}}\|_{\infty} = \eta$. 即

$$\|A\|_{\infty} = \eta = \max_{1 \leq i \leq n} \sum_{j=1}^n |a_{ij}|.$$

矩阵2-范数是谱范数的证明

$$\|A\|_2 = \max_{\|\mathbf{x}\|_2=1} \|A\mathbf{x}\|_2 = \max_{\|\mathbf{x}\|_2=1} [(A\mathbf{x})^T A\mathbf{x}]^{\frac{1}{2}} = \max_{\|\mathbf{x}\|_2=1} [\mathbf{x}^T (A^T A)\mathbf{x}]^{\frac{1}{2}}.$$

由于 $A^T A$ 是对称半正定 (A 不一定非奇异), 故可设其特征值为: $\lambda_1 \geq \cdots \geq \lambda_n \geq 0$, 并设对应的标准正交特征向量为 $\mathbf{v}_1, \cdots, \mathbf{v}_n \in \mathbb{R}^n$ (由于 $A^T A$ 是对称矩阵, 故其特征子空间是完备的, 即特征值都是非亏损的). 这样 $\forall \mathbf{x} \in \mathbb{R}^n$ 满足 $\|\mathbf{x}\|_2 = 1$, 都可以由 $\mathbf{v}_1, \cdots, \mathbf{v}_n$ 线性表出, 即 $\mathbf{x} = \sum_{i=1}^n \alpha_i \mathbf{v}_i$,

且 $\|\mathbf{x}\|_2 = 1 \Rightarrow \mathbf{x}^T \mathbf{x} = 1 \Rightarrow \sum_{i=1}^n \alpha_i^2 \mathbf{v}_i^T \mathbf{v}_i = \sum_{i=1}^n \alpha_i^2 = 1$. 于是,

$\mathbf{x}^T A^T A \mathbf{x} = \sum_{i=1}^n \lambda_i \alpha_i^2 \leq \lambda_1$. 另一方面, 特别取 $\mathbf{x} = \mathbf{v}_1$, 则有

$$\mathbf{x}^T A^T A \mathbf{x} = \mathbf{v}_1^T A^T A \mathbf{v}_1 = \lambda_1 \Rightarrow \|A\|_2 = \max_{\|\mathbf{x}\|_2=1} \|A\mathbf{x}\|_2 = \sqrt{\lambda_1} = \sqrt{\lambda_{\max}(A^T A)}.$$

谱范数的常用性质

谱范数的计算复杂度高于另两种范数（计算特征值复杂度较高）。但谱范数在理论分析中很有用，以下介绍谱范数的一些常用性质。

定理2.1.5 谱范数的常用性质

设 $A \in \mathbb{R}^{n \times n}$, 则

- ① $\|A\|_2 = \max\{|\mathbf{y}^T A \mathbf{x}| : \mathbf{x}, \mathbf{y} \in \mathbb{R}^n, \|\mathbf{x}\|_2 = \|\mathbf{y}\|_2 = 1\}$;
- ② $\|A^T\|_2 = \|A\|_2 = \sqrt{\|A^T A\|_2}$;
- ③ $\forall$ orthogonal matrices $U, V \in \mathbb{R}^{n \times n}$, 有 $\|UA\|_2 = \|AV\|_2 = \|A\|_2$.

请尝试证明!

F-范数

另一个常用且易于计算的矩阵范数是

$$\|A\|_F = \left(\sum_{i=1}^n \sum_{j=1}^n |a_{ij}|^2 \right)^{\frac{1}{2}},$$

称为Frobenius范数（简称f-范数）。它由向量的2-范数推广而来，但它本身不是任何向量范数诱导的矩阵范数。

谱半径的定义

定义2.1.4 谱半径的定义

设 $A \in \mathbb{C}^{n \times n}$, 则称

$$\rho(A) = \max\{|\lambda| : \lambda \in \sigma(A)\}$$

为 A 的 **谱半径**, 这里 $\sigma(A)$ 表示 A 的全体特征值集合, 简称 A 的 **谱**。

以下定理说明了矩阵的谱半径和其范数之间的关系。

定理 2.1.6 谱半径和矩阵范数的关系

设 $A \in \mathbb{C}^{n \times n}$, 则

- ① $\forall \mathbb{C}^{n \times n}$ 上的矩阵范数 $\|\cdot\|$, 有 $\rho(A) \leq \|A\|$;
- ② $\forall \varepsilon > 0, \exists \mathbb{C}^{n \times n}$ 上的矩阵范数 $\|\cdot\|$, s.t. $\|A\| \leq \rho(A) + \varepsilon$.

定理 2.1.6的证明

先证明第1部分。

设 $\mathbb{C}^n$ 中的非零向量 $\boldsymbol{x}$ 满足: $A\boldsymbol{x} = \lambda\boldsymbol{x}$, 且 $|\lambda| = \rho(A)$. 则

$$\rho(A)\|\boldsymbol{x}\boldsymbol{e}_1^T\| = |\lambda|\|\boldsymbol{x}\boldsymbol{e}_1^T\| = \|\lambda\boldsymbol{x}\boldsymbol{e}_1^T\| = \|A\boldsymbol{x}\boldsymbol{e}_1^T\| \leq \|A\|\|\boldsymbol{x}\boldsymbol{e}_1^T\| \Rightarrow \rho(A) \leq \|A\|.$$

思考一下为何不可以这样证明:

$$\rho(A)\|\boldsymbol{x}\| = \|\lambda\boldsymbol{x}\| = \|A\boldsymbol{x}\| \leq \|A\|\|\boldsymbol{x}\| \Rightarrow \rho(A) \leq \|A\|?$$

定理 2.1.6的证明.

再证明第2部分。这部分的证明是构造性的，即构造出一种矩阵范数来满足要证的不等式。

利用矩阵的Jordan分解，可知存在非奇异阵 $X \in \mathbb{C}^{n \times n}$ (X 就是 A 的Jordan分解变换矩阵)，使得

$$X^{-1}AX = \begin{pmatrix} \lambda_1 & \delta_1 & & & \\ & \lambda_2 & \delta_2 & & \\ & & \ddots & \ddots & \\ & & & \lambda_{n-1} & \delta_{n-1} \\ & & & & \lambda_n \end{pmatrix},$$

其中 $\delta_i = 1$ 或者 0 (按什么规则取1或者0?) $\forall \varepsilon > 0$, 令 $D_\varepsilon = \text{diag}(1, \varepsilon, \dots, \varepsilon^{n-1})$, 则

$$D_\varepsilon^{-1}X^{-1}AXD_\varepsilon = \begin{pmatrix} \lambda_1 & \varepsilon\delta_1 & & & \\ & \lambda_2 & \varepsilon\delta_2 & & \\ & & \ddots & \ddots & \\ & & & \lambda_{n-1} & \varepsilon\delta_{n-1} \\ & & & & \lambda_n \end{pmatrix},$$

定理 2.1.6的证明..

构造矩阵范数:

$$\|G\|_{\varepsilon} = \|D_{\varepsilon}^{-1}X^{-1}GX D_{\varepsilon}\|_{\infty}, \quad G \in \mathbb{C}^{n \times n},$$

易证 $\|\cdot\|_{\varepsilon}$ 是由向量范数

$$\|\mathbf{x}\|_{XD_{\varepsilon}} = \|(XD_{\varepsilon})^{-1}\mathbf{x}\|_{\infty}$$

诱导的矩阵范数, 而且

$$\|A\|_{\varepsilon} = \|D_{\varepsilon}^{-1}X^{-1}AX D_{\varepsilon}\|_{\infty} = \max_{1 \leq i \leq n} (|\lambda_i| + |\varepsilon\delta_i|) \leq \rho(A) + \varepsilon,$$

这里假定 $\delta_n = 0$.

方阵幂收敛的充要条件

定理 2.1.7 方阵幂收敛的充要条件

设 $A \in \mathbb{C}^{n \times n}$, 则

$$\lim_{k \rightarrow \infty} A^k = 0 \Leftrightarrow \rho(A) < 1.$$

先证明必要性, 即证: $\lim_{k \rightarrow \infty} A^k = 0 \Rightarrow \rho(A) < 1$.

设 $\lambda \in \sigma(A)$, 且 $\rho(A) = |\lambda|$. 则 $\forall k \in \mathbb{Z}^+$ 有 $\lambda^k \in \sigma(A^k)$. 于是定理2.1.6

$$\rho(A)^k = |\lambda|^k = |\lambda^k| \leq \rho(A^k) \leq \|A^k\|_2.$$

再证明充分性, 即证: $\lim_{k \rightarrow \infty} A^k = 0 \Leftarrow \rho(A) < 1$.

由 $\rho(A) < 1$, 利用定理2.1.6, 必有矩阵范数 $\|\cdot\|$ 使得 $\|A\| < 1$, 从而

$$0 \leq \|A^k\| \leq \|A\|^k \rightarrow 0, \quad k \rightarrow \infty.$$

由定理2.1.7推出...

定理 2.1.8

设 $A \in \mathbb{C}^{n \times n}$, 则

- ① $\sum_{k=0}^{\infty} A^k$ 收敛 $\Leftrightarrow \rho(A) < 1$;
- ② 当 $\sum_{k=0}^{\infty} A^k$ 收敛时, 有 $\sum_{k=0}^{\infty} A^k = (I - A)^{-1}$, 而且存在 $\mathbb{C}^{n \times n}$ 上的矩阵范数 $\|\cdot\|$, 使得 $\forall m \in \mathbb{N}$, 成立

$$\left\| (I - A)^{-1} - \sum_{k=0}^m A^k \right\| \leq \frac{\|A\|^{m+1}}{1 - \|A\|}.$$

推论2.1.1

设 $\|\cdot\|$ 是 $\mathbb{C}^{n \times n}$ 上的满足条件 $\|I\| = 1$ 的矩阵范数, 并假定 $A \in \mathbb{C}^{n \times n}$ 满足 $\|A\| < 1$, 则 $I - A$ 可逆, 且

$$\|(I - A)^{-1}\| \leq \frac{1}{1 - \|A\|}.$$