

第二章 线性方程组的敏度分析与消去法的舍入误差分析

第三节 基本运算的舍入误差分析

张振宇

上海财经大学 数学学院

June 17, 2020

计算机中浮点数的表示

浮点数 $f = \pm w \times \beta^J, L \leq J \leq U$. 其中 β 为基(base), 即使用几进制数。如: 使用二进制数, 则 $\beta = 2$. J 是阶码, w 是尾数, 一般表示为: $w = 0.d_1d_2 \cdots d_t$. 这里 t 是尾数的位数, 称为字长。显然 $0 \leq d_i < \beta$. 如果 $d_1 \neq 0$, 则称该浮点数为规格化浮点数。

计算机所能表示的规格化浮点数全体为

$$\mathcal{F} = \{0\} \cup \{f : f = \pm 0.d_1d_2 \cdots d_t \times \beta^J, 0 \leq d_i < \beta, d_1 \neq 0, L \leq J \leq U\}.$$

常用四元组 $\mathcal{F} = (\beta, t, L, U)$ 来表示。例如: $\mathcal{F} = (2, 52, -63, 64)$ 就是二进制双精度浮点数集合。集合 $\mathcal{F} = (\beta, t, L, U)$ 是一个包含 $2(\beta - 1)\beta^{t-1}(U - L + 1) + 1$ 个数的有限集合, 这些数对称分布在 $[m, M]$ 和 $[-M, -m]$ 这两个区间里。其中,

$$m = \beta^{L-1}, \quad M = \beta^U(1 - \beta^{-t}).$$

而且这些数并不是等距分布的。

舍入误差的产生

舍入误差产生的主要原因：

- 由于计算机只能表示 $\mathcal{F}$ 中有限个数，因此无法精确表示 $[m, M]$ 和 $[-M, -m]$ 中的全体实数。例如：有个数 $\alpha \in [m, M]$ ，但是 $\alpha \notin \mathcal{F}$ ，这时只能用 $\mathcal{F}$ 中离 α 最近的数 $\tilde{\alpha}$ 来近似替代 α ，这样就产生了舍入误差 $|\alpha - \tilde{\alpha}|$ 。
- 即使计算机能精确表示参与运算的数，但其运算结果却未必能精确表示，比如： $\tilde{\mu}, \tilde{\nu} \in \mathcal{F}$ ，但是 $\tilde{\mu} \times \tilde{\nu} \notin \mathcal{F}$ 。那么其计算结果也将产生舍入误差。

从以上舍入误差产生的原因来看，用 $\mathcal{F}$ 中怎样的数来表示 $[-M, -m]$ 或者 $[m, M]$ 中的实数，对于讨论舍入误差的大小很重要！

实数的浮点数表示

记 $x \in \mathbb{R}$ 得浮点数表示为 $\text{fl}(x)$. 则

$$\text{fl}(x) = \begin{cases} 0, & x = 0; \\ \text{按舍入法或截断法取近似数}, & |x| \in [m, M]; \\ \text{异常处理, 如上下溢出或非数}, & \text{其他情况。} \end{cases}$$

其中

$$\text{fl}(x) = \begin{cases} \mathcal{F} \text{中最接近 } x \text{ 的数 } f, & \text{舍入法;} \\ \mathcal{F} \text{中最满足 } |f| \leq |x| \text{ 的最接近于 } x \text{ 的数 } f, & \text{截断法。} \end{cases}$$

比如: 若 $\mathcal{F} = (10, 3, 0, 2)$, $x = -5.45627$, 则按舍入法有 $\text{fl}(x) = -0.546 \times 10^1$; 若按截断法有 $\text{fl}(x) = -0.545 \times 10^1$.

相对舍入误差

定理2.3.1 用机器精度表示舍入误差

设 $m \leq |x| \leq M$, 其中 m, M 由数系集合 $\mathcal{F} = (\beta, t, L, U)$ 给出定义。则

$$\text{fl}(x) = x(1 + \delta), \quad |\delta| \leq u,$$

其中 u 为机器精度:

$$u = \begin{cases} \frac{1}{2}\beta^{1-t}, & \text{by roundoff;} \\ \beta^{1-t}, & \text{by truncating.} \end{cases}$$

定理2.3.1的证明

不妨设 $x \in [m, M]$. $x \in [-M, -m]$ 的证明完全类似。设 $x \in [\beta^{\alpha-1}, \beta^\alpha)$, $\alpha \in \mathbb{Z}$. α 唯一确定。比如：0.012345 在 $[10^{-2}, 10^{-1})$ 中，这里 $\alpha = -1$. 可以看出： $[\beta^{\alpha-1}, \beta^\alpha)$ 中所有浮点数以间距 $\beta^{\alpha-t}$ 分布，这是因为 $\beta^{\alpha-t}$ 是该数最末位的一个单位。仍以 0.012345 为例，其末位的单位是 10^{-6} ，而该数的 $\alpha = -1, t = 5$, 因此 $10^{-1-5} = 10^{-6}$. 这样一来，按舍入法（四舍五入）舍入到末位，其误差的绝对值应该不超过末位的半个单位；而按截断法截断到末位，其误差的绝对值应该不超过末位的一个单位。从而

舍入法：

$$|\text{fl}(x) - x| \leq \frac{1}{2}\beta^{\alpha-t} = \frac{1}{2}\beta^{\alpha-1}\beta^{1-t} \leq \frac{1}{2}x\beta^{1-t} \Rightarrow \frac{|\text{fl}(x) - x|}{x} \leq \frac{1}{2}\beta^{1-t};$$

截断法：

$$|\text{fl}(x) - x| \leq \beta^{\alpha-t} = \beta^{\alpha-1}\beta^{1-t} \leq x\beta^{1-t} \Rightarrow \frac{|\text{fl}(x) - x|}{x} \leq \beta^{1-t}.$$

基本浮点运算的误差分析

注2.3.1

为了方便, $\text{fl}(x)$ 也表示为

$$\text{fl}(x) = \frac{x}{1 + \delta}, |\delta| < u.$$

对于浮点数的基本运算（四则运算）： $+$, $-$, $\times$, $/$, 我们用 $\circ$ 表示其中任何一种运算。 $\text{fl}(a \circ b)$, $a, b \in \mathcal{F}$ 表示先进行运算得到精确实数, 再按舍入规则（四舍五入或者截断）表示成浮点数。需要说明的是, 如果 $|a \circ b| > M$ 或者 $|a \circ b| < m$. 那么会触发异常（上溢出或下溢出）。因此在不发生异常的前提下, 我们有

定理2.3.2 浮点数基本运算误差

设 $a, b \in \mathcal{F}$, 则 $\text{fl}(a \circ b) = (a \circ b)(1 + \delta)$, $|\delta| \leq u$.

n 维向量乘积的浮点运算误差界

利用定理2.3.2可以估计更复杂的运算相对误差界，比如两个 n 维向量做数量积的运算。

例2.3.1 设 $\mathbf{x}, \mathbf{y}$ 是两个由浮点数构成的 n 维向量，估计 $|\text{fl}(\mathbf{x}^T \mathbf{y}) - \mathbf{x}^T \mathbf{y}|$ 的上界。

解：记

$$S_k = \text{fl} \left(\sum_{i=1}^k x_i y_i \right),$$

则利用定理2.3.2可得： $S_1 = x_1 y_1 (1 + \gamma_1)$, $|\gamma_1| \leq u$;

$S_k = \text{fl}(S_{k-1} + \text{fl}(x_k y_k)) = [S_{k-1} + x_k y_k (1 + \gamma_k)](1 + \delta_k)$, $|\delta_k|, |\gamma_k| \leq u$, 于是

$$\text{fl}(\mathbf{x}^T \mathbf{y}) = S_n = \sum_{i=1}^n x_i y_i (1 + \gamma_i) \prod_{j=i}^n (1 + \delta_j) = \sum_{i=1}^n \left[(1 + \gamma_i) \prod_{j=i}^n (1 + \delta_j) \right] x_i y_i \stackrel{\text{def}}{=} \sum_{i=1}^n (1 + \varepsilon_i) x_i y_i.$$

这里定义 $\delta_1 = 0$. 利用后面的定理2.3.3可得

$$|\text{fl}(\mathbf{x}^T \mathbf{y}) - \mathbf{x}^T \mathbf{y}| \leq \sum_{i=1}^n |\varepsilon_i| |x_i y_i| \leq 1.01 n u \sum_{i=1}^n |x_i y_i|.$$

定理2.3.3

定理2.3.3

若 $|\delta_i| \leq u$ 且 $nu \leq 0.01$, 那么

$$1 - nu \leq \prod_{i=1}^n (1 + \delta_i) \leq 1 + 1.01nu,$$

或者写成

$$\prod_{i=1}^n (1 + \delta_i) = 1 + \delta, \quad |\delta| \leq 1.01nu.$$

定理2.3.3的证明

由于 $|\delta_i| \leq u, i = 1, \dots, n$, 因此

$$(1 - u)^n \leq \prod_{i=1}^n (1 - |\delta_i|) \leq \prod_{i=1}^n (1 + \delta_i) \leq \prod_{i=1}^n (1 + |\delta_i|) \leq (1 + u)^n.$$

估计 $(1 - u)^n$ 的下界, 可利用函数 $(1 - x)^n (0 < x < 1)$ 的Taylor展开:

$$(1 - x)^n = 1 - nx + \frac{n(n-1)}{2}(1 - \theta x)^{n-2}x^2, \quad 0 < \theta < 1,$$

可知 $1 - nx \leq (1 - x)^n$. 因此立得

$$1 - 1.01nu \leq 1 - nu \leq (1 - u)^n.$$

定理2.3.3的证明.

再估计 $(1 + u)^n$ 的上界。利用 e^x 的幂级数展开

$$e^x = 1 + x + \frac{x^2}{2!} + \frac{x^3}{3!} + \cdots = 1 + x + \frac{x}{2} \cdot x \cdot \left(1 + \frac{x}{3} + \frac{2x}{4!} + \cdots\right)$$

立得：当 $0 \leq x \leq 0.01$ 时，有

$$1 + x \leq e^x \leq 1 + x + \frac{0.01}{2}xe^x \leq 1 + 1.01x, \quad (e^{0.01} < 2).$$

令上式中的 $x = u$ ，则 $(1 + u)^n \leq e^{nu}$ 。若令 $x = nu$ ，则有 $e^{nu} \leq 1 + 1.01nu$ 。从而定理结论成立。□

再回到例2.3.1的结论： $|\text{fl}(\mathbf{x}^T \mathbf{y}) - \mathbf{x}^T \mathbf{y}| \leq 1.01nu \sum_{i=1}^n |x_i y_i|$ 。我们可以看出，如

果 $|\mathbf{x}^T \mathbf{y}| \ll \sum_{i=1}^n |x_i y_i|$ ，那么 $\text{fl}(\mathbf{x}^T \mathbf{y})$ 的相对误差可能很大。

矩阵基本运算的舍入误差分析

引入记号: $|E| = (|e_{ij}|)$, $E \in \mathbb{R}^{n \times n}$, 并规

定 $|E| \leq |F| \Leftrightarrow |e_{ij}| \leq |f_{ij}|, i, j = 1, \dots, n$. 设 A, B 是由 $\mathcal{F}$ 中的元素构成的 $n \times n$ 矩阵, 且 $\alpha \in \mathcal{F}$, 则由定理2.3.2并利用例2.3.1有:

$$\text{fl}(\alpha A) = \alpha A + E, \quad |E| \leq u|\alpha A|;$$

$$\text{fl}(A + B) = (A + B) + E, \quad |E| \leq u|A + B|;$$

$$\text{fl}(AB) = AB + E, \quad |E| \leq 1.01nu|A||B|.$$

注意到, 有可能 $|AB| \ll |A||B|$, 因此矩阵乘积的相对误差未必很小。通常在计算内积时 (事实上在做乘法运算时也一样), 不对阶 (加法要先向上对阶), 即按照 $2t$ 字长计算, 再舍入到 t 字长。

向前、向后误差分析法

上述三个舍入误差界的估计, 是通过估计计算解与精确解之间的误差得到的, 舍入误差的界与精确解有关。这种误差分析方法称为向前误差分析法。但实际更常用的是向后误差分析法。以下举例说明。假设 A, B 是由 $\mathcal{F}$ 元素构成的 2×2 阶上三角矩阵, 则由定理2.3.1可知

$$\text{fl}(AB) = \begin{pmatrix} a_{11}b_{11}(1 + \varepsilon_1) & [a_{11}b_{12}(1 + \varepsilon_2) + a_{12}b_{22}(1 + \varepsilon_3)](1 + \varepsilon_4) \\ 0 & a_{22}b_{22}(1 + \varepsilon_5) \end{pmatrix}$$

其中, $|\varepsilon_i| \leq u, i = 1, 2, 3, 4, 5$. 若令

$$\tilde{A} = \begin{pmatrix} a_{11} & a_{12}(1 + \varepsilon_3)(1 + \varepsilon_4) \\ 0 & a_{22}(1 + \varepsilon_5) \end{pmatrix}, \tilde{B} = \begin{pmatrix} b_{11}(1 + \varepsilon_1) & b_{12}(1 + \varepsilon_2)(1 + \varepsilon_4) \\ 0 & b_{22} \end{pmatrix},$$

则可以验证 $\text{fl}(AB) = \tilde{A}\tilde{B}$, 而且 $\tilde{A} = A + E, \tilde{B} = B + F$, 其中 $|E| \leq 3u|A|, |F| \leq 3u|B|$.

向前、向后误差分析法.

以上例子说明矩阵乘积的浮点运算结果 $\text{fl}(AB)$ 可以看成是两个受到微小扰动的矩阵 $\tilde{A}$ 和 $\tilde{B}$ 做精确乘积的结果。这种把计算过程产生的误差归结为：具有误差的原始数据的精确运算的误差分析方法，被称为**向后误差分析法**。其优点在于可将浮点数的运算转化为实数的精确运算，从而大大简化误差分析过程。