

第二章 线性方程组的敏度分析与 消去法的舍入误差分析

第四节 列主元 *Gauss* 消去法的舍入误差分析

第五节 计算解的精度估计和迭代改善

张振宇

上海财经大学 数学学院

April 17, 2020

本节主要内容

利用浮点数运算的舍入误差分析理论，对求解线性方程组的列主元Gauss消去法进行向后误差分析。即证明：用列主元Gauss消去法求解线性方程组 $A\mathbf{x} = \mathbf{b}$ 时，其计算近似解 $\tilde{\mathbf{x}}$ 满足

$$(A + E)\tilde{\mathbf{x}} = \mathbf{b}.$$

并给出误差矩阵 E 的上界估计。

以下给出证明的线路图。

证明过程线路

- ① 给出在一定条件下, n 阶矩阵 A 的三角分解的向后误差分析: $\tilde{L}\tilde{U} = A + E, |E| \leq 2.05n\mathbf{u}|\tilde{L}||\tilde{U}|$; 引理2.4.1
- ② 从上一步结论推导出: 列主元 Gauss 消去过程的向后误差分析: $\tilde{L}\tilde{U} = \tilde{P}A + E, |E| \leq 2.05n\mathbf{u}|\tilde{L}||\tilde{U}|$, 同时方程组 $A\mathbf{x} = \mathbf{b}$ 求解化为三角方程组 $\tilde{L}\mathbf{y} = \tilde{P}A, \tilde{U}\mathbf{x} = \mathbf{y}$ 的求解; 推论2.4.1
- ③ 给出求解三角方程组 $S\mathbf{x} = \mathbf{b}$ (S 是上(下)三角矩阵) 的向后误差分析: $(S + H)\tilde{\mathbf{x}} = \mathbf{b}, |H| \leq 1.01n\mathbf{u}|S|$, 并给出 Gauss 消去法增长因子的定义; 引理2.4.2
- ④ 利用以上结论, 给出本节主要定理, 即列主元 Gauss 消去法求解线性方程组 $A\mathbf{x} = \mathbf{b}$ 的向后误差分析: $(A + \delta A)\tilde{\mathbf{x}} = \mathbf{b}, \|\delta A\|_{\infty} / \|A\|_{\infty} \leq 4.09n^3\rho\mathbf{u}$. 定理2.4.1

三角分解的向后退入误差分析

引理 2.4.1 三角分解的向后退入误差分析

设 $n \times n$ 浮点数矩阵 $A = (a_{ij})$ 有三角分解, 且矩阵阶数 n 满足 $1.01nu \leq 0.01$, 这里 u 是机器精度。则用 Gauss 消去法计算得到的单位下三角矩阵 $\tilde{L}$ 和上三角矩阵 $\tilde{U}$ 满足

$$\tilde{L}\tilde{U} = A + E,$$

其中

$$|E| \leq 2.05nu|\tilde{L}||\tilde{U}|.$$

引理2.4.1的证明

为了证明引理2.4.1，我们需要对前面的知识做一个简单的回顾。

- 用Gauss消去法实现矩阵 $A = (a_{ij})$ 的LU分解过程。其中，
 - $i \leq j$ 时， u_{ij} 的计算过程为：

$$\begin{aligned}a_{ij}^{(0)} &= a_{ij}; \\a_{ij}^{(k)} &= a_{ij}^{(k-1)} - l_{ik}a_{kj}^{(k-1)}, \quad k = 1, \dots, i-1; \\u_{ij} &= a_{ij}^{(i-1)} = a_{ij}^{(i-2)} - l_{i,i-1}u_{i-1,j}.\end{aligned}$$

- $i > j$ 时， l_{ij} 的计算过程为：

$$\begin{aligned}a_{ij}^{(0)} &= a_{ij}; \\a_{ij}^{(k)} &= a_{ij}^{(k-1)} - l_{ik}a_{kj}^{(k-1)}, \quad k = 1, \dots, j-1; \\l_{ij} &= a_{ij}^{(j-1)} / u_{jj} = \left[a_{ij}^{(j-2)} - l_{i,j-1}u_{j-1,j} \right] / u_{jj}.\end{aligned}$$

引理2.4.1的证明.

- 定理2.3.2 设 $a, b \in \mathcal{F}$, 则 $\text{fl}(a \circ b) = (a \circ b)(1 + \delta)$, $|\delta| \leq u$.
- 定理2.3.3 若 $|\delta_i| \leq u$ 且 $nu \leq 0.01$, 那么 $1 - nu \leq \prod_{i=1}^n (1 + \delta_i) \leq 1 + 1.01nu$,

或者写成 $\prod_{i=1}^n (1 + \delta_i) = 1 + \delta$, $|\delta| \leq 1.01nu$.

思考一下定理的证明...

列主元Gauss消去法进行三角分解的舍入误差分析（推论2.4.1）

由于矩阵交换行或列并不带来舍入误差。因此引理2.4.1.结论完全适用于列主元Gauss消去法计算LU分解过程。即

推论2.4.1列主元Gauss消去三角分解的舍入误差分析

设 $n \times n$ 浮点数矩阵 A 是非奇异的，且 $1.01nu \leq 0.01$. 则用列主元Gauss消去法计算得到的单位下三角阵 $\tilde{L}$, 上三角阵 $\tilde{U}$ 以及排列方阵 $\tilde{P}$ 满足

$$\tilde{L}\tilde{U} = \tilde{P}A + E,$$

其中

$$|E| \leq 2.05nu|\tilde{L}||\tilde{U}|.$$

三角形方程组求解的舍入误差分析（引理2.4.2）

按照Gauss消去法求解线性方程组 $A\mathbf{x} = \mathbf{b}$ 的算法过程，在进行了三角分解 $A = \tilde{L}\tilde{U}$ 之后，要求解两个三角形方程组：

$$\tilde{L}\mathbf{y} = \tilde{P}\mathbf{b}, \quad \tilde{U}\mathbf{x} = \mathbf{y}.$$

所以接下来，需要给出求解三角形方程组的舍入误差分析：

引理2.4.2 三角形方程组求解的舍入误差分析

设 $n \times n$ 浮点数矩阵 S 是非奇异的，且 $1.01nu \leq 0.01$. 则用前代法（或者回代法）求解三角形线性方程组 $S\mathbf{x} = \mathbf{b}$ 所得计算近似解 $\tilde{\mathbf{x}}$ 满足

$$(S + H)\tilde{\mathbf{x}} = \mathbf{b},$$

其中

$$|H| \leq 1.01nu|S|.$$

线性方程组 $A\mathbf{x} = \mathbf{b}$ 求解的舍入误差分析

有了推论2.4.1和引理2.4.2我们就可以推出采用列主元Gauss消去法求解线性方程组 $A\mathbf{x} = \mathbf{b}$ 的向后误差分析。

假设 $\tilde{P}A + E = \tilde{L}\tilde{U}$, $(\tilde{L} + F)\tilde{\mathbf{y}} = \tilde{P}\mathbf{b}$, $(\tilde{U} + G)\tilde{\mathbf{x}} = \tilde{\mathbf{y}}$, 其中 $|F| \leq 1.01n\mathbf{u}|\tilde{L}|$, $|G| \leq 1.01n\mathbf{u}|\tilde{U}|$. 则

$$(\tilde{L} + F)(\tilde{U} + G)\tilde{\mathbf{x}} = \tilde{P}\mathbf{b} \Rightarrow (\tilde{L}\tilde{U} + F\tilde{U} + \tilde{L}G + FG)\tilde{\mathbf{x}} = \tilde{P}\mathbf{b}$$

$$\Rightarrow (\tilde{P}A + E + F\tilde{U} + \tilde{L}G + FG)\tilde{\mathbf{x}} = \tilde{P}\mathbf{b}$$

$$\Rightarrow \tilde{P} \left[A + \tilde{P}^T(E + F\tilde{U} + \tilde{L}G + FG) \right] \tilde{\mathbf{x}} = \tilde{P}\mathbf{b}$$

$$\Rightarrow \left[A + \tilde{P}^T(E + F\tilde{U} + \tilde{L}G + FG) \right] \tilde{\mathbf{x}} = \mathbf{b}, \quad \tilde{P} \text{ is orthogonal.}$$

$$\stackrel{\text{def}}{\Rightarrow} (A + \delta A)\tilde{\mathbf{x}} = \mathbf{b}.$$

线性方程组 $Ax = b$ 求解的舍入误差分析.

$$\begin{aligned} |\delta A| &\leq \tilde{P}^T \left(|E| + |F||\tilde{U}| + |\tilde{L}||G| + |F||G| \right) \\ &\leq \tilde{P}^T \left(2.05nu|\tilde{L}||\tilde{U}| + 1.01nu|\tilde{L}||\tilde{U}| + 1.01nu|\tilde{L}||\tilde{U}| + 0.01 \times 1.01nu|\tilde{L}||\tilde{U}| \right) \\ &\leq 4.09nu\tilde{P}|\tilde{L}||\tilde{U}|. \end{aligned}$$

为了方便计算, 使用矩阵的 $\|\cdot\|_\infty$ 范数进行误差分析。考虑到上式中, $\tilde{L}$ 的元素 $|\tilde{l}_{ij}| \leq 1$, 因此 $\|\tilde{L}\|_\infty \leq n$. 在引入矩阵增长因子

$$\rho = \max_{i,j} |\tilde{u}_{ij}| / \max_{i,j} |a_{ij}|$$

后, 有

$$\|\tilde{U}\|_\infty \leq n \max_{i,j} |\tilde{u}_{ij}| = n\rho \max_{ij} |a_{ij}| \leq n\rho \|A\|_\infty \Rightarrow \|\delta A\|_\infty \leq 4.09n^3 u \rho \|A\|_\infty.$$

列主元Gauss消去法求解线性方程组误差分析主要定理

定理2.4.1

设 $n \times n$ 浮点数矩阵 A 是非奇异的, 且 $1.01n\mathbf{u} \leq 0.01$. 则用列主元Gauss消去法求解线性方程组 $A\mathbf{x} = \mathbf{b}$ 所得计算近似解 $\tilde{\mathbf{x}}$ 满足

$$(A + \delta A)\tilde{\mathbf{x}} = \mathbf{b},$$

其中

$$\frac{\|\delta A\|_{\infty}}{\|A\|_{\infty}} \leq 4.09n^3\rho\mathbf{u}.$$

列主元Gauss消去法求解线性方程组误差分析结论

- Gauss消去法求解过程中引入舍入误差而得到的近似解相当于系数矩阵作某种扰动而得到的扰动方程组的精确解。
- 虽然理论上可以证明 $\rho \leq 2^{n-1}$ ，且上界可以达到，但在实际计算中，一般 ρ 很小，不会超过 n 。此外，定理2.4.1中的上界 $4.09n^3\rho u$ 也比 $\|\delta A\|_\infty / \|A\|_\infty$ 的精确值大很多。实际计算时，几乎都有 $\|\delta A\|_\infty / \|A\|_\infty \approx u$ 。
- 从以上结论来看，一般 δA 的元素比起 A 的元素的初始误差（测量误差、模型误差等）小很多，在这个意义上，列主元Gauss消去法求解线性方程组是稳定的。

第五节 计算解的精度估计和迭代改进

残量、条件数和解的精度估计

记用某种算法数值计算得到的线性方程组 $A\mathbf{x} = \mathbf{b}$ 近似解为 $\tilde{\mathbf{x}}$, 则我们把向量

$$\mathbf{r} = \mathbf{b} - A\tilde{\mathbf{x}}$$

称为解的残量 (residual)。而

$$\mathbf{r} = \mathbf{b} - A\tilde{\mathbf{x}} = A\mathbf{x} - A\tilde{\mathbf{x}} = A(\mathbf{x} - \tilde{\mathbf{x}}),$$

因此当 A 非奇异时, 有

$$\|\mathbf{x} - \tilde{\mathbf{x}}\| = \|A^{-1}\mathbf{r}\| \leq \|A^{-1}\| \|\mathbf{r}\|.$$

注意到: $\|\mathbf{b}\| \leq \|A\| \|\mathbf{x}\|$, 因此有

$$\frac{\|\mathbf{x} - \tilde{\mathbf{x}}\|}{\|\mathbf{x}\|} \leq \|A^{-1}\| \|A\| \frac{\|\mathbf{r}\|}{\|\mathbf{b}\|}, \text{ especially } \frac{\|\mathbf{x} - \tilde{\mathbf{x}}\|_{\infty}}{\|\mathbf{x}\|_{\infty}} \leq \kappa_{\infty}(A) \frac{\|\mathbf{r}\|_{\infty}}{\|\mathbf{b}\|_{\infty}}.$$

解的精度估计

上面估计式的右端上界表达式中, $\|\mathbf{r}\|_\infty$, $\|\mathbf{b}\|_\infty$ 以及 $\|A\|_\infty$ 这些量都容易计算得到, 但是 $\|A^{-1}\|_\infty$ 却不易计算。为了估计解的计算精度, 本节的核心内容就是如何估计 $\|A^{-1}\|_\infty$ 的上界。方法来自于著名的LAPACK.

以下几点是我们开始估计前必须了解和关注的:

- $\forall M \in \mathbb{R}^{n \times n}$, $\|M\|_\infty = \|M^T\|_1$, 因此这里只讨论矩阵 $\|\cdot\|_1$ 的计算估计;
- 由于 $\|A^{-1}\|_\infty = \max_{\|\mathbf{x}\|_1=1} \|A^{-T}\mathbf{x}\|_1$, 其中的矩阵-向量乘积 $\mathbf{y} = A^{-T}\mathbf{x}$ 可以通过求

解方程组 $A^T\mathbf{y} = \mathbf{x}$ 得到, 由于在估计列主元Gauss消去法求解方程组时, A 的LU分解已经求出, 故利用三角方程组求解, 可以快速计算得到 $\mathbf{y}$.

计算 $\|B\|_1$ 的问题等价于求凸函数在凸集上的最大值问题分析

$\forall B \in \mathbb{R}^{n \times n}$, 定义

$$f(\mathbf{x}) = \|B\mathbf{x}\|_1 = \sum_{i=1}^n \left| \sum_{j=1}^n b_{ij}x_j \right|, \quad \mathcal{D} = \{\mathbf{x} \in \mathbb{R}^n : \|\mathbf{x}\|_1 \leq 1\},$$

由于 $\mathcal{D}$ 是 $\mathbb{R}^n$ 中的单位超球, 故是凸集; 而 $\forall \mathbf{x}_1, \mathbf{x}_2 \in \mathcal{D}, \lambda \in (0, 1)$, 有

$$\begin{aligned} f(\lambda \mathbf{x}_1 + (1 - \lambda) \mathbf{x}_2) &= \|B(\lambda \mathbf{x}_1 + (1 - \lambda) \mathbf{x}_2)\|_1 \\ &= \|\lambda B\mathbf{x}_1 + (1 - \lambda) B\mathbf{x}_2\|_1 \\ &\leq \|\lambda B\mathbf{x}_1\|_1 + \|(1 - \lambda) B\mathbf{x}_2\|_1 \\ &= \lambda \|B\mathbf{x}_1\|_1 + (1 - \lambda) \|B\mathbf{x}_2\|_1 \\ &= \lambda f(\mathbf{x}_1) + (1 - \lambda) f(\mathbf{x}_2) \end{aligned}$$

计算 $\|B\|_1$ 的问题等价于求凸函数在凸集上的最大值问题分析。

故 $f(\mathbf{x})$ 是 $\mathcal{D}$ 上的凸函数。这样，计算 $\|B\|_1 = \max_{\|\mathbf{x}\|_1=1} \|B\mathbf{x}\|_1 = \max_{\mathbf{x} \in \mathcal{D}} f(\mathbf{x})$ 变成了求凸函数 $f(\mathbf{x})$ 在凸集 $\mathcal{D}$ 上的最大值问题。

设 $\mathbf{x}_0 = (x_j^{(0)}) \in \mathcal{D}$, 使得 $\sum_{j=1}^n b_{ij}x_j^{(0)} \neq 0, i = 1, \dots, n$.

令 $\mathbf{v} = (\xi_i)$, 其中 $\xi_i = \operatorname{sgn} \left(\sum_{j=1}^n b_{ij}x_j^{(0)} \right)$, 则当 $\mathbf{x} = (x_j)$ 在 $\mathbf{x}^{(0)}$ 附近时, 有

$$f(\mathbf{x}) = \sum_{i=1}^n \sum_{j=1}^n \xi_i b_{ij} x_j.$$

于是

$$\frac{\partial f(\mathbf{x})}{\partial x_k} = \sum_{i=1}^n \xi_i b_{ik} = \mathbf{v}^T \mathbf{b}_k, k = 1, \dots, n, \quad \text{where } B = (\mathbf{b}_1, \dots, \mathbf{b}_n).$$

计算 $\|B\|_1$ 的问题等价于求凸函数在凸集上的最大值问题分析..

这样，便可得到函数 $f(\boldsymbol{x})$ 在点 $\boldsymbol{x}_0$ 处的梯度

$$\nabla f(\boldsymbol{x}_0) = \left(\frac{\partial f(\boldsymbol{x}_0)}{\partial x_1}, \dots, \frac{\partial f(\boldsymbol{x}_0)}{\partial x_n} \right) = \boldsymbol{v}^T (\boldsymbol{b}_1, \dots, \boldsymbol{b}_n) = \boldsymbol{v}^T B = (B^T \boldsymbol{v})^T.$$

记 $\boldsymbol{w} = B\boldsymbol{x}_0$, $\boldsymbol{z} = B^T \boldsymbol{v}$, 则 $\nabla f(\boldsymbol{x}_0) = \boldsymbol{z}^T$. 基于以下定理可得估计 $\|B\|_1$ 的算法。

定理2.5.1

假定 $B, \boldsymbol{x}_0, \boldsymbol{v}, \boldsymbol{w}$ 和 $\boldsymbol{z}$ 按以上定义，则

- ① 若 $\|\boldsymbol{z}\|_\infty \leq \boldsymbol{z}^T \boldsymbol{x}_0$ ，则 $\|\boldsymbol{w}\|_1 = \|B\boldsymbol{x}_0\|_1$ 是 $f(\boldsymbol{x}) = \|B\boldsymbol{x}\|_1$ 在 $\mathcal{D}$ 中的局部极大值；
- ② 若 $\|\boldsymbol{z}\|_\infty > \boldsymbol{z}^T \boldsymbol{x}_0$ ，则 $\|B\boldsymbol{e}_j\|_1 > \|B\boldsymbol{x}_0\|_1$ ，其中 j 满足 $|z_j| = \|\boldsymbol{z}\|_\infty$.

估计 $\|B\|_1$ 的算法推导

定理2.5.1的第1个结论告诉我们，寻找 $f(\boldsymbol{x})$ 在 $\mathcal{D}$ 中的最大值点 $\boldsymbol{x}_0$ （由于 $f(\boldsymbol{x})$ 是凸函数，故其在 $\mathcal{D}$ 中的局部极大值就是最大值），关键是寻找一点的梯度 $\boldsymbol{z}$ 与该点的数量积不小于梯度的最大分量的点。

定理2.5.1的第2个结论告诉我们，寻找的过程可以按照：若第1个结论的条件不满足，则取 $\boldsymbol{x}_0 = \boldsymbol{e}_j$ 回到第1个结论的条件处进行比较，这里 j 是梯度的最大分量。这一过程一直持续下去，直到第1个结论的条件满足为止。这一过程形象地称为“盲人爬山法”。

估计 $\|B\|_1$ 的算法2.5.1

算法2.5.1 估计矩阵1范数：优化法

```
1 k=1
2 while k==1
3     w=B*x; v=sign(w); z=B'*
4     if norm(z, inf)<=z'*x
5         v=norm(w, 1)
6         k=0
7     else
8         x=ej (j=argmax(z))
9         k=1
10    end
11 end
```

注：该算法执行是需预先给定一个迭代初值。 $\mathcal{D}$ 任意向量均可作为初始迭代向量。一般可取 $\mathbf{x} = (\frac{1}{n}, \dots, \frac{1}{n})^T$ 作为初始迭代向量。

利用列主元Gauss消去法求解线性代数方程组所得计算解 $\tilde{\mathbf{x}}$ 的精度估计

有了矩阵1-范数的估计算法之后，在已经获得方程组系数矩阵的 A 的列主元三角分解： $PA = LU$ 的前提下，利用以下的步骤，仅需花费 $O(n^2)$ 的运算量，就可以估计出 $\|A^{-1}\|_{\infty}$ 的值，从而计算解 $\tilde{\mathbf{x}}$ 的精度。

- 由于 $\|A^{-1}\|_{\infty} = \|A^{-T}\|_1$ ，所以只需要利用算法2.5.1估计 A^{-T} 的1-范数，即取算法2.5.1中的 $B = A^{-T}$ 即可。
- 算法中需要计算 $\mathbf{w} = B\mathbf{x} = A^{-T}\mathbf{x}$ 和 $\mathbf{z} = B^T\mathbf{v} = A^{-1}\mathbf{v}$ 。考虑到 A 的三角分解已经得到，因此可以通过求解方程组 $A^T\mathbf{w} = \mathbf{x}$ 和 $A\mathbf{z} = \mathbf{v}$ 求得。根据第一章中三角方程组求解的计算量分析可知，其计算量为 $O(n^2)$ 。

这样，按以下步骤便可估计计算解的精度。

计算解 $\tilde{\mathbf{x}}$ 的精度估计

- ① 应用算2.5.1于 $B + A^{-T}$ 上的到 $\|A^{-1}\|_{\infty}$ 的估计值 $\tilde{\nu}$;
- ② 分别计算 $\|\mathbf{r}\|_{\infty} = \|A\tilde{\mathbf{x}}\|_{\infty}$ 、 $\|\mathbf{b}\|_{\infty}$ 和 $\|A\|_{\infty}$ 分别得到它们的计算值: $\tilde{\gamma}$ 、 $\tilde{\beta}$ 和 $\tilde{\mu}$;
- ③ 计算

$$\tilde{\rho} = \frac{\tilde{\nu}\tilde{\mu}\tilde{\gamma}}{\tilde{\beta}} \approx \|A^{-1}\|_{\infty}\|A\|_{\infty}\frac{\|\mathbf{r}\|_{\infty}}{\|\mathbf{b}\|_{\infty}}$$

作为计算解 $\tilde{\mathbf{x}}$ 的相对误差估计。

虽然大多数情况下, $\tilde{\rho}$ 可以作为计算解相对误差的良好估计, 但是由于舍入误差以及 A 的病态引起的三角分解的不准确, 都有可能使该估计值远远小于计算解的实际相对误差。该问题需要进一步深入分析。

迭代改进

记 $f(\mathbf{x}) = A\mathbf{x} - \mathbf{b} = -\mathbf{r}$. 把Newton迭代法

$$x_{k+1} = x_k - \frac{f(x_k)}{f'(x_k)}$$

应用到 $f(\mathbf{x})$ 上, 即 x_k 取为计算近似解 $\tilde{\mathbf{x}}$, x_{k+1} 取为 $\hat{\mathbf{x}}$ (期待迭代精度能改善的解), 特别注意到, 导数项变为

$$\nabla f(\tilde{\mathbf{x}}) = \nabla f(\mathbf{x}) \Big|_{\mathbf{x}=\tilde{\mathbf{x}}} = A \quad (\text{why})$$

于是Newton法变为

$$\hat{\mathbf{x}} = \tilde{\mathbf{x}} - A^{-1}(-\mathbf{r}) = \tilde{\mathbf{x}} + A^{-1}\mathbf{r} \stackrel{\text{def}}{=} \tilde{\mathbf{x}} + \mathbf{z}.$$

其中, $\mathbf{z} = A^{-1}\mathbf{r}$ 可以看做是误差补偿项, 可通过求解方程组 $A\mathbf{z} = \mathbf{r}$ (利用 A 的三角分解) 得到。实际计算表明, 在 A 病态不严重的情形下, 可以期望 $\hat{\mathbf{x}}$ 比计算解 $\tilde{\mathbf{x}}$ 更接近于精确解, 从而计算解的精度得到改进。