

第五章 Krylov子空间方法初步

周解勇

上海财经大学 数学学院

为什么是Krylov子空间?

求解非奇异线性方程组:

$$Ax = b \quad (1)$$

这里 A 是 n 阶非奇异矩阵, b 是 n 阶向量, 其精确解是 $x = A^{-1}b$ 。如何用 A 和 b 来表示 $A^{-1}b$ 呢?
假设 A 的特征多项式为 $p(\lambda) = |\lambda I - A| = \lambda^n + \alpha_{n-1}\lambda^{n-1} + \cdots + \alpha_1\lambda + \alpha_0$.
则:

$$p(A) = A^n + \alpha_{n-1}A^{n-1} + \cdots + \alpha_1A + \alpha_0I = 0$$

为什么是Krylov子空间?

因此

$$\begin{aligned}A^n + \alpha_{n-1}A^{n-1} + \cdots + \alpha_1A &= -\alpha_0I \\A(A^{n-1} + \alpha_{n-1}A^{n-2} + \cdots + \alpha_1I) &= -\alpha_0I \\A\left(-\frac{1}{\alpha_0}A^{n-1} - \frac{\alpha_{n-1}}{\alpha_0}A^{n-2} - \cdots - \frac{\alpha_1}{\alpha_0}I\right) &= I\end{aligned}$$

即

$$A^{-1} = -\frac{1}{\alpha_0}A^{n-1} - \frac{\alpha_{n-1}}{\alpha_0}A^{n-2} - \cdots - \frac{\alpha_1}{\alpha_0}I$$

$$A^{-1}b = -\frac{1}{\alpha_0}A^{n-1}b - \frac{\alpha_{n-1}}{\alpha_0}A^{n-2}b - \cdots - \frac{\alpha_1}{\alpha_0}b \in \text{span}\{b, Ab, A^2b, \dots, A^{n-1}b\}$$

Krylov子空间

- 定义：形如

$$\mathcal{K}_m(A, v) \equiv \text{span}\{v, Av, A^2v, \dots, A^{m-1}v\}$$

的空间称为 m 阶的Krylov子空间，可以简单地写成 $\mathcal{K}_m$.

- 性质：

- Krylov子空间由一个矩阵和一个向量唯一确定.
- $\mathcal{K}_1 \subset \mathcal{K}_2 \subset \dots$.
- $\mathcal{K}_m$ 中任意一个向量 x 都可以表示成 $x = p(A)v$.
其中, $p(A)$ 是次数不超过 $m - 1$ 的多项式.

定义

向量 v 的关于 A 的最小多项式: 若多项式 $p(x)$ 满足 $p(A)v = 0$ 次数最低的首项系数为1的非零多项式, 则称 $p(x)$ 是 v 关于 A 的最小多项式, 这个多项式的次数称为 v 关于 A 的阶, 记为 $\text{grade}(v)$ 。

极小多项式的性质

性质1:若 v 的阶为 k , 则 $\mathcal{K}_k$ 是 A 的一个不变子空间, 并且 $\mathcal{K}_m = \mathcal{K}_k$ 对所有的 $m \geq k$ 都成立。

证明: 假设 v 的关于 A 的最小多项式是 $p(A) = A^k + a_{k-1}A^{k-1} + \cdots + a_1A + a_0I$, 则

$$p(A)v = A^k v + a_{k-1}A^{k-1}v + \cdots + a_1Av + a_0Iv = 0,$$

故 $A^k v = -(a_{k-1}A^{k-1}v + \cdots + a_1Av + a_0Iv)$, 即 $A^k v$ 可由 $A^{k-1}v, \cdots, Av, v$ 线性表出。所以 $\mathcal{K}_k$ 是 A 的一个不变子空间, 并且 $\mathcal{K}_m = \mathcal{K}_k$ 对所有的 $m \geq k$ 都成立。

极小多项式的性质

性质2: Krylov子空间 $\mathcal{K}_m$ 的维数为 m 当且仅当向量 v 关于 A 的阶不超过 m , 即

$$\dim(\mathcal{K}_m) = m \Leftrightarrow \text{grade}(v) \geq m.$$

证明: “ $\Rightarrow$ ” 因为 $\mathcal{K}_m$ 的维数为 m , 所以 $v, Av, \dots, A^{m-1}v$ 是 $\mathcal{K}_m$ 的一组基. 则

$$\alpha_0 v + \alpha_1 Av + \dots + \alpha_{n-1} A^{m-1} v = 0 \Leftrightarrow \alpha_0 = \alpha_1 = \dots = \alpha_{n-1} = 0.$$

若 $\alpha_0, \alpha_1, \dots, \alpha_{n-1}$ 不全为0, 则

$$\alpha_0 v + \alpha_1 Av + \dots + \alpha_{n-1} A^{m-1} v \neq 0.$$

所以 $\text{grade}(v) > m - 1$, 即 $\text{grade}(v) \geq m$.

Krylov子空间

证明 (续) :

“ $\Leftarrow$ ” 若 $\text{grade}(v) \geq m$, 则对任意 $\alpha_0, \alpha_1, \dots, \alpha_{n-1}$ 不全为0, 可以得到 $\alpha_0 v + \alpha_1 Av + \dots + \alpha_{n-1} A^{m-1} v \neq 0$, 故

$$\alpha_0 v + \alpha_1 Av + \dots + \alpha_{n-1} A^{m-1} v = 0 \Leftrightarrow \alpha_0 = \alpha_1 = \dots = \alpha_{n-1} = 0.$$

所以 $v, Av, \dots, A^{m-1}v$ 线性无关, 即

$$\dim(\mathcal{K}_m) = m.$$

因此

$$\dim(\mathcal{K}) = \min\{m, \text{grade}(v)\}.$$

Krylov子空间迭代法框架

对于非奇异线性方程组 $Ax = b$, 任取 $x_0 \in C^n$, 记 $r_0 = b - Ax_0$ 。

构造第 k 近似解 x_k 如下:

$$x_k = x_0 + c_k, c_k \in \mathcal{K}_k$$

这里 $\mathcal{K}_k$ 为某个近似子空间, 满足: $\mathcal{K}_1 \subset \mathcal{K}_2 \subset \dots$ 。

- 若 $x_0 = 0$, 则需求解 $Ac_k = b$, 所以得到 $c_k \in \mathcal{K}_k = \text{span}\{b, Ab, \dots, A^{k-1}b\}$
- 若 $x_0 \neq 0$, 则需求解 $A(x_0 + c_k) = b$, 即 $Ac_k = b - Ax_0 = r_0$, 所以

$$c_k \in \mathcal{K}_k = \text{span}\{r_0, Ar_0, \dots, A^{k-1}r_0\}$$

Krylov子空间迭代法框架

为了确定 $x_k = x_0 + c_k, c_k \in \mathcal{K}_k$, 需要求解 $c_k = V_k y_k$, 这里 V_k 是 $\mathcal{K}_k$ 的一组基。因为

$$r_k = b - A(x_0 + c_k) = r_0 + AV_k y_k,$$

确定 c_k 的方法为: $r_k = r_0 - AV_k y_k \perp \mathcal{L}_k$, 这里 $\mathcal{L}_k$ 称为矫正子空间。关于矫正子空间的选取方法如下:

- 垂直残量法: 取 $\mathcal{L}_k = \mathcal{K}_k$, 即 $r_k \perp \mathcal{K}_k = r_0 - AV_k y_k \perp \mathcal{K}_k$ 。所以有

$$V_k^H (r_0 - AV_k y_k) = 0 \Leftrightarrow y_k = (V_k^H AV_k)^{-1} V_k^H r_0.$$

- 极小残量法: 取 $\mathcal{L}_k = A\mathcal{K}_k$, 即 $r_k = r_0 - AV_k y_k \perp A\mathcal{K}_k$, 即

$$r_0 - AV_k y_k \perp AV_k \Leftrightarrow \min_y \|r_0 - AV_k y\|.$$

Krylov子空间迭代法框架

令 x^* 是 $Ax = b$ 的精确解, 注意到 $r_k = b - Ax_k = A(x^* - x_k)$, 为了确定 c_k , 我们有 $r_k \perp B\mathcal{K}_k$, ($B = I$ or A)。则对于 $\mathcal{K}_k$ 一组基向量按列形成的矩阵 $V_k = [v_1, \dots, v_k]$ 有:

$$(A(x^* - x_k), Bv_i) = (B^H A(x^* - x_k), v_i) = 0, \quad (i = 1, 2, \dots, k)$$

这就等价于要求 x_k 满足 $(x^* - x_k) \perp_{B^H A} \mathcal{K}_k$.

当 $B^H A$ 是正定矩阵时(为什么?), 所求的 x_k 就是 x^* 在 $\mathcal{K}_k$ 上的正交投影, 即求

$$\min \|x^* - x_k\|_{B^H A}.$$

Krylov子空间迭代法框架

- ① 若 A 正定, 取 $B = I$, 即较正子空间为 $\mathcal{K}_k$, 要求满足 $(x^* - x_k) \perp_A \mathcal{K}_k$, 即求 $\min \|x^* - x_k\|_A$ 。此时得到的算法有共轭梯度法(CG)。
- ② 若 A 非奇异,
 - 当 $B = A$ 时, 即较正子空间为 $A\mathcal{K}_k$, 要求满足 $(x^* - x_k) \perp_{A^H A} \mathcal{K}_k$, 即要求 $\min \|x^* - x_k\|_{A^H A}$ 。此时得到的算法是广义极小残量法(GMRES)。
 - 当 $B = I$ 时, 这时 x_k 不是 x^* 的正交投影, 所得的算法是正交残量法(FOM)。

Arnoldi方法

对 m 阶Krylov子空间的基 $\{r_0, Ar_0, \dots, A^{m-1}r_0\}$ 做Gram-Schmidt正交化过程, 就有如下的Arnoldi算法:

Arnoldi算法

- ① $v_1 = \frac{r_0}{\|r_0\|}$
- ② For $j = 1, 2, \dots, m$ Do :
 - ① Compute $h_{ij} = (Av_j, v_i), i = 1, 2, \dots, j$
 - ② Compute $w_j = Av_j - \sum_{i=1}^j h_{ij}v_i$
- ③ $h_{j+1,j} = \|w_j\|_2$
- ④ If $h_{j+1,j} = 0$ then stop.
- ⑤ $v_{j+1} = \frac{w_j}{h_{j+1,j}}$
- ⑥ EndDo

$$w_j = Av_j - \sum_{i=1}^j h_{ij}v_i, \quad v_{j+1} = \frac{w_j}{h_{j+1,j}}$$

在算法中, 当 $j = 1$ 时, $v_1 = \frac{r_0}{\|r_0\|}$, $h_{11} = (Av_1, v_1)$, 且由上式, 可知 $h_{21}v_2 = Av_1 - h_{11}v_1$, 即

$$Av_1 = [v_1, v_2] \begin{bmatrix} h_{11} \\ h_{21} \end{bmatrix}.$$

当 $j = 2$ 时, $h_{12} = (Av_1, v_2)$, $h_{22} = (Av_2, v_2)$, 同样由上式, 可知 $h_{32}v_3 = Av_2 - h_{12}v_1 - h_{22}v_2$, 即 $Av_2 = h_{12}v_1 + h_{22}v_2 + h_{32}v_3$, 所以

$$A[v_1, v_2] = [v_1, v_2, v_3] \begin{bmatrix} h_{11} & h_{12} \\ h_{21} & h_{22} \\ 0 & h_{32} \end{bmatrix}.$$

$$w_j = Av_j - \sum_{i=1}^j h_{ij}v_i, \quad v_{j+1} = \frac{w_j}{h_{j+1,j}}$$

在算法中, 当 $j = 3$ 时, $h_{13} = (Av_1, v_3)$, $h_{23} = (Av_2, v_3)$, $h_{33} = (Av_3, v_3)$ 且由上式, 可知 $h_{43}v_4 = Av_3 - h_{13}v_1 - h_{23}v_2 - h_{33}v_3$, 即

$$\begin{aligned} A[v_1, v_2, v_3] &= [v_1, v_2, v_3, v_4] \begin{bmatrix} h_{11} & h_{12} & h_{13} \\ h_{21} & h_{22} & h_{23} \\ 0 & h_{32} & h_{33} \\ 0 & 0 & h_{43} \end{bmatrix} \cdot (\text{upper Hessenberg matrix}) \\ &= [v_1, v_2, v_3] \begin{bmatrix} h_{11} & h_{12} & h_{13} \\ h_{21} & h_{22} & h_{23} \\ 0 & h_{32} & h_{33} \end{bmatrix} + h_{43}v_4e_3^T \end{aligned}$$

Arnoldi方法的重要关系式

由上述分析可知: $Av_j = h_{j+1,j}v_{j+1} + \sum_{i=1}^j h_{ij}v_i = \sum_{i=1}^{j+1} h_{ij}v_i$,
所以得到

$$AV_m = V_{m+1}\bar{H}_m \quad (2)$$

又有

$$\begin{aligned} AV_m &= V_{m+1}\bar{H}_m \\ &= (V_m, v_{m+1}) \begin{pmatrix} H_m \\ h_{m+1,m}e_m^T \end{pmatrix} \\ &= V_m H_m + h_{m+1,m}v_{m+1}e_m^T \end{aligned}$$

两边同时乘以 V_m^T , 由正交性得

$$V_m^T AV_m = H_m \quad (3)$$

Arnoldi方法

若Arnoldi方法在第 m 步中断, 则 $h_{m+1,m} = 0$,
所以

$$AV_m = V_m H_m. \quad (4)$$

即 V_m 是 A 的不变子空间, 也说明 v_1 关于 A 的最小多项式的次数为 m 。
因此Krylov子空间的维数最多只需要扩大到 m 维即可。

Arnoldi方法

Arnoldi方法用于投影法的直观图

$$A \quad V_m = V_m \quad H_m + w_m e_m^T$$

定理

由Arnoldi方法得到的 $\{v_1, \dots, v_m\}$ 是 $\mathcal{K}_k = \text{span}\{r_0, Ar_0, \dots, A^{m-1}r_0\}$ 的一组标准正交基。

证明：先证标准正交性。假设在上述算法中的第 m 步之前没有中断，由算法过程可以知道： $v_2 = Av_1 - (Av_1, v_1)v_1$ ，则

$$\begin{aligned}(v_1, v_2) &= (v_1, Av_1 - (Av_1, v_1)v_1) \\ &= (v_1, Av_1) - (Av_1, v_1)(v_1, v_1) \\ &= 0\end{aligned}$$

假设对于所有小于 m 的正整数， $v_1, v_2, \dots, v_{m-1}$ 两两正交，

Arnoldi方法

证明（续）：

则对任意小于 m 的整数 l 有：

$$\begin{aligned}(v_m, v_l) &= \alpha_m (Av_{m-1} - \sum_{i=1}^{m-1} (Av_{m-1}, v_i) v_i, v_l) \\&= \alpha_m \left[(Av_{m-1}, v_l) - \sum_{i=1}^{m-1} (Av_{m-1}, v_i) (v_i, v_l) \right] \\&= \alpha_m [(Av_{m-1}, v_l) - (Av_{m-1}, v_l) (v_l, v_l)] \\&= 0\end{aligned}$$

故 $v_1, v_2, \dots, v_m$ 两两正交。算法的第5步，标准性显然成立。

Arnoldi方法

证明 (续) :

下证 $\{v_1, \dots, v_m\} \sim \{r_0, Ar_0, \dots, A^{m-1}r_0\}$ 。因为 $r_0 = \|r_0\|v_1$, 所以 $\{r_0, Ar_0, \dots, A^{m-1}r_0\} \sim \{v_1, Av_1, \dots, A^{m-1}v_1\}$, 因此只需证明

$$\{v_1, \dots, v_m\} \sim \{v_1, Av_1, \dots, A^{m-1}v_1\}.$$

用 $q_{j-1}(A)$ 表示次数不超过 $j-1$ 次的关于 A 的多项式, 当 $k=1$ 时, $v_1 = q_0(A)v_1$, 这里 $q_0(A) = 1$ 。假设对所有小于 j 的整数 k , v_k 可以表示成 $v_k = q_{k-1}(A)v_1$ 。当 $k = j+1$ 时,

$$\begin{aligned} h_{j+1,j}v_{j+1} &= Av_j - \sum_{i=1}^j h_{ij}v_i \\ &= Aq_{j-1}(A)v_1 - \sum_{i=1}^j h_{ij}q_{i-1}(A)v_1 \end{aligned}$$

Arnoldi方法

证明（续）：

所以 $v_{j+1} = q_j(A)v_1$, 即 $v_1, v_2, \dots, v_m$ 可由 $v_1, Av_1, \dots, A^{m-1}v_1$ 表示。而

$$Av_j = h_{j+1,j}v_{j+1} + \sum_{i=1}^j h_{ij}v_i = \sum_{i=1}^{j+1} h_{ij}v_i$$

因此 Av_j 可由 $v_1, v_2, \dots, v_{j+1}$ 表示,

所以 $v_1, Av_1, \dots, Av_{m-1}$ 可由 $v_1, v_2, \dots, v_m$ 表示。

而 $Av_j = Aq_{j-1}(A)v_1 = q_j(A)v_1$,

所以 $v_1, q_1(A)v_1, \dots, q_{m-1}(A)v_1$ 可由 $v_1, v_2, \dots, v_m$ 表示。

易知 $v_1, Av_1, \dots, A^{m-1}v_1$ 可由 $v_1, v_2, \dots, v_m$ 表示。证毕。

Arnoldi方法

为了防止正交化丢失，实际计算中使用修改的Gram-Schmidt正交化过程(modified Gram-Schmidt)来实现Arnoldi过程。

- ① $v_1 = \frac{r_0}{\|r_0\|}$
- ② For $j = 1, 2, \dots, m$ Do :
 - ① Compute $w_j = Av_j$
 - ② Compute For $i = 1, 2, \dots, j$ Do :
 - ① Compute $h_{ij} = (w_j, v_i)$
 - ② Compute $w_j = w_j - h_{ij}v_i$
 - ③ EndDo
- ③ $h_{j+1,j} = \|w_j\|_2$
- ④ If $h_{j+1,j} = 0$ then stop.
- ⑤ $v_{j+1} = \frac{w_j}{h_{j+1,j}}$
- ⑥ EndDo

选取 $\mathcal{L} = \mathcal{K} = \mathcal{K}_m(A, r_0)$, 求 x_m , 满足 *Galerkin condition* : $b - Ax_m \perp \mathcal{K}_m$.
令

$$v_1 = \frac{r_0}{\|r_0\|_2}, \beta = \|r_0\|_2$$

则

$$r_0 = \beta v_1$$

由 *Arnoldi* 过程知: $V_m^T A V_m = H_m$,

由 V_m 列向量的正交性知道:

$$\begin{aligned} V_m^T r_0 &= V_m^T (\beta v_1) \\ &= \beta e_1 \end{aligned}$$

要求 x_m 满足Galerkin condition : $b - Ax_m \perp \mathcal{K}_m$.

则

$$\begin{aligned} V_m^T (b - Ax_m) &= 0 \\ V_m^T (b - A(x_0 + V_m y_m)) &= 0 \\ V_m^T r_0 &= V_m^T A V_m y_m \end{aligned}$$

故

$$\beta e_1 = H_m y_m$$

即

$$y_m = H_m^{-1} (\beta e_1)$$

所以

$$x_m = x_0 + V_m y_m = x_0 + V_m H_m^{-1} (\beta e_1)$$



$$\begin{aligned}b - Ax_m &= b - A(x_0 + V_m y_m) \\&= r_0 - AV_m y_m \\&= \beta v_1 - V_m H_m y_m - h_{m+1,m} v_{m+1} e_m^T y_m \\&= \beta v_1 - V_m H_m H_m^{-1} (\beta e_1) - h_{m+1,m} v_{m+1} e_m^T y_m \\&= \beta v_1 - \beta v_1 - h_{m+1,m} e_m^T y_m v_{m+1} \\&= -h_{m+1,m} e_m^T y_m v_{m+1}\end{aligned}$$

所以 $\|b - Ax_m\|_2 = h_{m+1,m} |e_m^T y_m|$

- 当 $h_{m+1,m} = 0$ 时, $\|b - Ax_m\|_2 = 0$. 故找到了精确解.

在这里, 可以看出 $\|b - Ax_m\|_2$ 是 $h_{m+1,m}$ 的倍数, 由于 $h_{m+1,m}$ 是单调下降的, 因此当 $h_{m+1,m}$ 足够小时, 可以停止.

- ① Compute $r_0 = b - Ax_0$, $\beta := \| r_0 \|_2$, and $v_1 = \frac{r_0}{\beta}$
- ② Define the $m \times m$ matrix $H_m = h_{ij}$, $i, j = 1, 2, \dots, m$; Set $H_m = 0$
- ③ For $j = 1, 2, \dots, m + 1$ Do:
 - ④ Compute $w_j = Av_j$
 - ⑤ For $i = 1, 2, \dots, j$ Do:
 - ⑥ Compute $h_{ij} = (w_j, v_i)$ and $w_j = Av_j - h_{ij}v_i$
 - ⑦ EndDo
 - ⑧ $h_{j+1,j} = \| w_j \|_2$
 - ⑨ if $h_{j+1,j} = 0$, set $m = j$ and go to 13
 - ⑩ $v_{j+1} = \frac{w_j}{h_{j+1,j}}$
 - ⑪ EndDo
- ⑫ Compute $y_m = H_m^{-1} (\beta e_1)$ and $x_m = x_0 + V_m y_m = x_0 + V_m H_m^{-1} (\beta e_1)$
- ⑬ Compute $\| b - Ax_m \|_2 = h_{m+1,m} |e_m^T y_m|$

Restarted FOM

当 m 很大时, 利用FOM算法时, 需要存储所有的 $v_i (i = 1, 2, \dots, m)$, 代价非常大。有两种方法可以改善这种情况, 第一种是Restarted FOM方法, 通过控制维数来达到减少存储量的目的. 另一种是IOM方法, 通过进行不完全正交来减少计算量. 下面分别给出Restarted FOM 算法和IOM算法.

Restarted FOM(FOM(m)) :

- 1 Compute $r_0 = b - Ax_0, \beta = \| r_0 \|_2$, and $v_1 = \frac{r_0}{\beta}$
- 2 Generate the Arnoldi basis and the matrix H_m using the Arnoldi algorithm
- 3 starting with v_1
- 4 Compute $y_m = H_m^{-1} \beta e_1$ and $x_m = x_0 + V_m y_m$. If satisfied then stop.
- 5 Set $x_0 := x_m$ and go to 1

- 1 For $j = 1, 2, \dots, m + 1$ Do:
- 2 Compute $w_j = Av_j$
- 3 For $i = \max\{1, j - k + 1\}, \dots, j$ Do:
- 4 Compute $h_{ij} = (w_j, v_i)$
- 5 Compute $w_j = Av_j - h_{ij}v_j$
- 6 EndDo
- 7 Compute $h_{j+1,j} = \|w_j\|_2$ and $v_{j+1} = \frac{w_j}{h_{j+1,j}}$
- 8 EndDo

- v_{j+1} 仅与最近的 k 个 $v_{j-k+1}, \dots, v_j$ 正交, 破坏了正交性, 但降低了计算量, 减少了存储空间.
- 注意: 这里得到的 $h_{m+1,m}$ 已经不具备单调下降的性质.

在IOM方法的理论上, 以 $k = 3, m = 5$ 为例, 对 H_m 进行LU分解, 得到:

$$\begin{aligned}
 H_m &= \begin{bmatrix} h_{11} & h_{12} & h_{13} & & \\ h_{21} & h_{22} & h_{23} & h_{24} & \\ & h_{32} & h_{33} & h_{34} & h_{35} \\ & & h_{43} & h_{44} & h_{45} \\ & & & h_{54} & h_{55} \end{bmatrix} \\
 &= \begin{bmatrix} 1 & & & & \\ l_{21} & 1 & & & \\ & l_{32} & 1 & & \\ & & l_{43} & 1 & \\ & & & l_{54} & 1 \end{bmatrix} \begin{bmatrix} u_{11} & u_{12} & u_{13} & & \\ & u_{22} & u_{23} & u_{24} & \\ & & u_{33} & u_{34} & u_{35} \\ & & & u_{44} & u_{45} \\ & & & & u_{55} \end{bmatrix}
 \end{aligned}$$

$$\text{所以 } L_m = \begin{bmatrix} 1 & & & & \\ l_{21} & 1 & & & \\ & l_{32} & 1 & & \\ & & l_{43} & 1 & \\ & & & l_{54} & 1 \end{bmatrix}, U_m = \begin{bmatrix} u_{11} & u_{12} & u_{13} & & \\ & u_{22} & u_{23} & u_{24} & \\ & & u_{33} & u_{34} & u_{35} \\ & & & u_{44} & u_{45} \\ & & & & u_{55} \end{bmatrix}.$$

由于

$$\begin{aligned} x_m &= x_0 + V_m y_m \\ &= x_0 + V_m H_m^{-1} (\beta e_1) \\ &= x_0 + V_m U_m^{-1} L_m^{-1} (\beta e_1) \end{aligned}$$

令

$$P_m = V_m U_m^{-1}, Z_m = L_m^{-1} (\beta e_1)$$

则

$$x_m = x_0 + P_m Z_m$$

由 $P_m U_m = V_m$ 的最后一列可以得到:

$$[p_1, p_2, p_3, p_4, p_5] \begin{bmatrix} u_{11} & u_{12} & u_{13} & & & \\ & u_{22} & u_{23} & u_{24} & & \\ & & u_{33} & u_{34} & u_{35} & \\ & & & u_{44} & u_{45} & \\ & & & & u_{55} & \end{bmatrix} = [v_1, v_2, v_3, v_4, v_5]$$

$$p_3 u_{35} + p_4 u_{45} + p_5 u_{55} = v_5$$

一般地:

$$\sum_{i=m-k+1}^m u_{im} p_i = v_m$$

从而可以推出:

$$p_m = \frac{1}{u_{mm}} \left(v_m - \sum_{i=m-k+1}^{m-1} u_{im} p_i \right)$$

而

$$Z_m = \begin{bmatrix} Z_{m-1} \\ \zeta_m \end{bmatrix}$$

其中 $\zeta_m = -l_{m,m-1}\zeta_{m-1}$.

所以

$$\begin{aligned} x_m &= x_0 + P_m Z_m \\ &= x_0 + [P_{m-1}, p_m] \begin{bmatrix} Z_{m-1} \\ \zeta_m \end{bmatrix} \\ &= x_0 + P_{m-1} Z_{m-1} + \zeta_m p_m \\ &= x_{m-1} + \zeta_m p_m \end{aligned}$$

即

$$x_m = x_{m-1} + \zeta_m p_m$$

DIOM中 H_m 的LU分解如何实现?

仍以上式为例, 当 $k = 3, m + 1 = 6$ 时:

$$H_m = \begin{bmatrix} h_{11} & h_{12} & h_{13} & & & \\ h_{21} & h_{22} & h_{23} & h_{24} & & \\ & h_{32} & h_{33} & h_{34} & h_{35} & \\ & & h_{43} & h_{44} & h_{45} & h_{46} \\ & & & h_{54} & h_{55} & h_{56} \\ & & & & h_{65} & h_{66} \end{bmatrix}$$
$$= \begin{bmatrix} 1 & & & & & \\ l_{21} & 1 & & & & \\ & l_{32} & 1 & & & \\ & & l_{43} & 1 & & \\ & & & l_{54} & 1 & \\ & & & & l_{65} & 1 \end{bmatrix} \begin{bmatrix} u_{11} & u_{12} & u_{13} & & & \\ & u_{22} & u_{23} & u_{24} & & \\ & & u_{33} & u_{34} & u_{35} & \\ & & & u_{44} & u_{45} & u_{46} \\ & & & & u_{55} & u_{56} \\ & & & & & u_{66} \end{bmatrix}$$

DIOM算法

- 1 Choose x_0 and compute $r_0 = b - Ax_0, \beta := \| r_0 \|_2$, and $v_1 = \frac{r_0}{\beta}$
- 2 For $m = 1, 2, \dots$, until convergence Do:
- 3 Compute $h_i, i = \max\{1, m-k+1\}, \dots, m$, and v_{m+1} as in lines 2-7 of (IOM).
- 4 Update the factorization of H_m , ie. Obtain that last column of U_m using the previous K pivots. If $u_{mm} = 0$ stop
- 5 Compute $\zeta_m = \{ \text{if } m = 1 \text{ then } \beta, \text{ else } -l_{m,m-1}\zeta_{m-1} \}$
- 6 Compute $p_m = \frac{1}{u_{mm}} \left(v_m - \sum_{i=m-k+1}^{m-1} u_{im} p_i \right)$ (for $i < 0$, set $u_{im} p_i = 0$)
- 7 Compute $x_m = x_{m-1} + \zeta_m p_m$

注意

由于LU分解没有选择主元, *step4*中 u_{mm} 可能会导致过早终止!

GMRES算法的导出

$x_m \in x_0 + \mathcal{K}_m$, 则 $x_m = x_0 + V_m y$, 其中 y 是一个 m 维向量.
记

$$\begin{aligned}\min \|r_m\|_2 &= \min_{x \in \mathcal{K}_m} \|b - Ax\|_2 \\&= \min_{y \in \mathcal{R}^m} \|b - A(x_0 + V_m y)\|_2 \\&= \min_{y \in \mathcal{R}^m} \|r_0 - AV_m y\|_2 \\&= \min_{y \in \mathcal{R}^m} \|\beta v_1 - V_{m+1} \bar{H}_m y\|_2 \\&= \min_{y \in \mathcal{R}^m} \|V_{m+1}(\beta e_1 - \bar{H}_m y)\|_2 \\&= \min_{y \in \mathcal{R}^m} \|\beta e_1 - \bar{H}_m y\|_2\end{aligned}$$

GMRES算法

- 1 Choose x_0 and compute $r_0 = b - Ax_0, \beta := \| r_0 \|_2$, and $v_1 = \frac{r_0}{\beta}$
- 2 Define the $(m+1) \times m$ matrix $\bar{H}_m = \{h_{ij}\}$, $i, j = 1, 2, \dots, m$; Set $\bar{H}_m = 0$
- 3 For $j = 1, 2, \dots, m+1$ Do:
 - 4 Compute $w_j = Av_j$
 - 5 For $i = 1, 2, \dots, j$ Do:
 - 6 Compute $h_{ij} = (w_j, v_i)$
 - 7 Compute $w_j = Av_j - h_{ij}v_i$
 - 8 EndDo
 - 9 $h_{j+1,j} = \| w_j \|_2$
 - 10 If $h_{j+1,j} = 0$, set $m = j$ and go to 13
 - 11 $v_{j+1} = \frac{w_j}{h_{j+1,j}}$
 - 12 Endo
- 13 Compute y_m the minimizer of $\| \beta e_1 - \bar{H}_m y \|_2$ and $x_m = x_0 + V_m y_m$.

$\min \| \beta e_1 - \bar{H}_m y \|_2$ 的求解

可以利用平面旋转将上 *Hessenberg* 矩阵变换成上三角矩阵, 从而解决 $\| \beta e_1 - \bar{H}_m y \|_2$ 最小二乘问题.

这里的旋转矩阵为: $\Omega_i =$

$$\begin{bmatrix} 1 & & & & & \\ & \ddots & & & & \\ & & 1 & & & \\ & & & c_i & s_i & \\ & & & -s_i & c_i & \\ & & & & & 1 & \\ & & & & & & \ddots & \\ & & & & & & & 1 \end{bmatrix}.$$

其中 c_i, s_i 分别在第 i 列和第 $i + 1$ 列, 并且 $c_i^2 + s_i^2 = 1$.

$\min \| \beta e_1 - \bar{H}_m y \|_2$ 的求解

以 $m = 5$ 为例, 记 $\bar{H}_5 = \begin{bmatrix} h_{11} & h_{12} & h_{13} & h_{14} & h_{15} \\ h_{21} & h_{22} & h_{23} & h_{24} & h_{25} \\ & h_{32} & h_{33} & h_{34} & h_{35} \\ & & h_{43} & h_{44} & h_{45} \\ & & & h_{54} & h_{55} \\ & & & & h_{65} \end{bmatrix}, \bar{g}_0 = \begin{bmatrix} \beta \\ 0 \\ 0 \\ 0 \\ 0 \\ 0 \end{bmatrix}$

对 $\bar{H}_5$ 左乘 $\Omega_1 = \begin{bmatrix} c_1 & s_1 & & & \\ -s_1 & c_1 & & & \\ & & 1 & & \\ & & & 1 & \\ & & & & 1 \\ & & & & & 1 \end{bmatrix}$. 其中 $c_1 = \frac{h_{11}}{\sqrt{h_{11}^2 + h_{21}^2}}, s_1 = \frac{h_{21}}{\sqrt{h_{11}^2 + h_{21}^2}}$

$\min \| \beta e_1 - \bar{H}_m y \|_2$ 的求解

则

$$\bar{H}_5^{(1)} = \Omega_1 \bar{H}_5 = \begin{bmatrix} h_{11}^{(1)} & h_{12}^{(1)} & h_{13}^{(1)} & h_{14}^{(1)} & h_{15}^{(1)} \\ & h_{22}^{(1)} & h_{23}^{(1)} & h_{24}^{(1)} & h_{25}^{(1)} \\ & & h_{32} & h_{33} & h_{34} & h_{35} \\ & & & h_{43} & h_{44} & h_{45} \\ & & & & h_{54} & h_{55} \\ & & & & & h_{65} \end{bmatrix}, \bar{g}_1 = \Omega_1 \bar{g}_0 = \begin{bmatrix} c_1 \beta \\ -s_1 \beta \\ 0 \\ 0 \\ 0 \\ 0 \end{bmatrix}$$

$\min \| \beta e_1 - \bar{H}_m y \|_2$ 的求解

令

$$c_2 = \frac{h_{22}^{(1)}}{\sqrt{\left(h_{22}^{(1)}\right)^2 + h_{3,2}^2}}, \quad s_2 = \frac{h_{3,2}}{\sqrt{\left(h_{22}^{(1)}\right)^2 + h_{3,2}^2}}.$$

$$\text{得 } \Omega_1 = \begin{bmatrix} 1 & & & & \\ & c_2 & s_2 & & \\ & -s_2 & c_2 & & \\ & & & 1 & \\ & & & & 1 \\ & & & & & 1 \end{bmatrix}.$$

$\min \| \beta e_1 - \bar{H}_m y \|_2$ 的求解

$$\begin{aligned}
 \bar{H}_5^{(2)} &= \Omega_2 \bar{H}_5^{(1)} = \begin{bmatrix} 1 & & & & \\ & c_2 & s_2 & & \\ & -s_2 & c_2 & & \\ & & & 1 & \\ & & & & 1 \\ & & & & & 1 \end{bmatrix} \begin{bmatrix} h_{11}^{(1)} & h_{12}^{(1)} & h_{13}^{(1)} & h_{14}^{(1)} & h_{15}^{(1)} \\ & h_{22}^{(1)} & h_{23}^{(1)} & h_{24}^{(1)} & h_{25}^{(1)} \\ & & h_{32} & h_{33} & h_{34} & h_{35} \\ & & & h_{43} & h_{44} & h_{45} \\ & & & & h_{54} & h_{55} \\ & & & & & h_{65} \end{bmatrix} \\
 &= \begin{bmatrix} h_{11}^{(1)} & h_{12}^{(1)} & h_{13}^{(1)} & h_{14}^{(1)} & h_{15}^{(1)} \\ & h_{22}^{(2)} & h_{23}^{(2)} & h_{24}^{(2)} & h_{25}^{(2)} \\ & & 0 & h_{33}^{(2)} & h_{34}^{(2)} & h_{35}^{(2)} \\ & & & h_{43} & h_{44} & h_{45} \\ & & & & h_{54} & h_{55} \\ & & & & & h_{65} \end{bmatrix},
 \end{aligned}$$

$\min \| \beta e_1 - \bar{H}_m y \|_2$ 的求解

$$\begin{aligned} \bar{g}_1 &= \Omega_2 \bar{g}_1 = \begin{bmatrix} 1 & & & & & \\ & c_2 & s_2 & & & \\ & -s_2 & c_2 & & & \\ & & & 1 & & \\ & & & & 1 & \\ & & & & & 1 \end{bmatrix} \begin{bmatrix} c_1 \beta \\ -s_1 \beta \\ 0 \\ 0 \\ 0 \\ 0 \end{bmatrix} \\ &= \begin{bmatrix} c_1 \beta \\ -c_2 s_1 \beta \\ s_2 s_1 \beta \\ 0 \\ 0 \\ 0 \end{bmatrix} \end{aligned}$$

$\min \| \beta e_1 - \bar{H}_m y \|_2$ 的求解

令

$$c_i = \frac{h_{ii}^{(i-1)}}{\sqrt{\left(h_{ii}^{(i-1)}\right)^2 + h_{i+1,i}^2}}, \quad s_i = \frac{h_{i+1,i}}{\sqrt{\left(h_{ii}^{(i-1)}\right)^2 + h_{i+1,i}^2}}.$$

则可以得到相应的 $\Omega_i, i = 1, 2, \dots, 5$.

对 $\bar{H}_5$ 依次左乘 Ω_i , 得到

$$\bar{H}_5^{(5)} = \begin{bmatrix} h_{11}^{(1)} & h_{12}^{(1)} & h_{13}^{(1)} & h_{14}^{(1)} & h_{15}^{(1)} \\ & h_{22}^{(2)} & h_{23}^{(2)} & h_{24}^{(2)} & h_{25}^{(2)} \\ & & h_{33}^{(3)} & h_{34}^{(3)} & h_{35}^{(3)} \\ & & & h_{44}^{(4)} & h_{45}^{(4)} \\ & & & & h_{55}^{(5)} \end{bmatrix}, \quad \bar{g}_5 = \begin{bmatrix} \gamma_1 \\ \gamma_2 \\ \gamma_3 \\ \gamma_4 \\ \gamma_5 \\ \gamma_6 \end{bmatrix}$$

$\min \| \beta e_1 - \bar{H}_m y \|_2$ 的求解

令

$$Q_m = \Omega_m \Omega_{m-1} \cdots \Omega_1$$

则

$$\bar{R}_m = \bar{H}_m^{(m)} = Q_m \bar{H}_m, \bar{g}_m = Q_m (\beta e_1) = \begin{bmatrix} \gamma_1 \\ \gamma_2 \\ \vdots \\ \gamma_m \end{bmatrix}$$

由于 Q_m 正交, 则

$$\begin{aligned} \min \| \beta e_1 - \bar{H}_m y \|_2 &= \min \| Q_m (\beta e_1 - \bar{H}_m y) \|_2 \\ &= \min \| \bar{g}_m - \bar{R}_m y \|_2 \end{aligned}$$

性质1

$\text{rank}(AV_m) = \text{rank}(R_m)$, 若 $r_{mm} = 0$, 则 A 是奇异的.

Proof: 用 R_m 表示 $\bar{R}_m$ 去掉最后一行, g_m 表示 $\bar{g}_m$ 去掉最后一行.

$$\begin{aligned} AV_m &= V_{m+1} \bar{H}_m \\ &= V_{m+1} Q_m^T Q_m \bar{H}_m \\ &= V_{m+1} Q_m^T \bar{R}_m \end{aligned}$$

由于 $V_{m+1} Q_m^T$ 是正交矩阵, 则 $\text{rank}(AV_m) = \text{rank}(\bar{R}_m) = \text{rank}(R_m)$.

当 $r_{mm} = 0$ 时, $\text{rank}(R_m) \leq m - 1$,

则 $\text{rank}(AV_m) \leq m - 1$,

而 V_m 满秩,

所以 A 是奇异的.

性质2:

满足 $\min \| \beta e_1 - \bar{H}_m y \|_2$ 的 $y_m = R_m^{-1} g_m$.

Proof :

$$\begin{aligned} \| \beta e_1 - \bar{H}_m y \|_2^2 &= \| Q_m (\beta e_1 - \bar{H}_m y) \|_2^2 \\ &= \| \bar{g}_m - \bar{R}_m y \|_2^2 \\ &= |\gamma_{m+1}|^2 + \| g_m - R_m y \|_2^2 \end{aligned}$$

当 $\| g_m - R_m y \|_2^2 = 0$, 即 $y = R_m^{-1} g_m$ 时,

$\| \beta e_1 - \bar{H}_m y \|_2$ 取得最小值 $|\gamma_{m+1}|$.

性质3

GMRES第 m 步有 $b - Ax_m = V_{m+1} (\beta e_1 - \bar{H}_m y_m) = V_{m+1} Q_m^T (\gamma_{m+1} e_{m+1})$,
且 $\|b - Ax_m\|_2 = |\gamma_{m+1}|$.

Proof : 对 $\forall x = x_0 + V_m y$,

$$\begin{aligned} b - Ax &= V_{m+1} (\beta e_1 - \bar{H}_m y) \\ &= V_{m+1} Q_m^T Q_m (\beta e_1 - \bar{H}_m y) \\ &= V_{m+1} Q_m^T (\bar{g}_m - \bar{R}_m y) \end{aligned}$$

$$\text{当 } y_m = R_m^{-1} g_m \text{ 时, } \bar{R}_m y = \begin{bmatrix} g_m \\ 0 \end{bmatrix}.$$

所以

$$\bar{g}_m - \bar{R}_m y = \begin{bmatrix} 0 \\ 0 \\ \vdots \\ 0 \\ \gamma_m \end{bmatrix} = \gamma_{m+1} e_{m+1}$$

故

$$b - Ax_m = V_{m+1} Q_m^T (\gamma_{m+1} e_{m+1})$$

由于 $V_{m+1} Q_m^T$ 正交, 由保范性知: $\| b - Ax_m \|_2 = |\gamma_{m+1}|$

注意

- 另外, 由于

$$\bar{g}_m = \begin{bmatrix} \gamma_1 \\ \gamma_2 \\ \vdots \\ \gamma_m \end{bmatrix}$$

可以得到 $\gamma_{j+1} = -s_j \gamma_j$

- 在GMRES中, 事实上, 只可能在Arnoldi过程中跳出循环.
若第j步breakdown,
由

$$h_{j+1,j} = 0 \Rightarrow s_j = 0 \Rightarrow b - Ax_j = |\gamma_{j+1}| = |-s_j \gamma_j| = 0$$

因此可以有精确解.

性质4:

若 A 非退化, $GMRES$ 算法在第 j 步终止, 则 x_j 为精确解, 即 $h_{j+1,j} = 0 \Leftrightarrow x_j$ 是精确解。

Proof: “ $\Rightarrow$ ” 若 $h_{j+1,j} = 0$, 则 $s_j = 0$.

由于 A 非退化, 故 $\gamma_{jj} = h_{jj}^{(j-1)} \neq 0$.

所以 $\gamma_j \neq 0, \gamma_{j+1} = -s_j \gamma_j = 0$.

$\Rightarrow \|b - Ax_j\|_2 = |\gamma_{j+1}| = 0$

所以 x_j 是精确解.

“ $\Leftarrow$ ” 因为第 j 步是精确解, 而第 $j-1$ 步不是精确解, 得到 $s_j = 0$.

故 $h_{j+1,j} = 0$.

Restarted GMRES

当线性方程组维数过大时, GMRES存储量和计算量都会以 m 倍增长。为了解决这个问题, 我们介绍 重开始*GMRES*法.即控制维数最多扩大到 m , 若第 m 步近似解 x_m 没有到达精确度要求, 则令 $x_m = x_0$,重新进行*GMRES*算法, 直到得到达到精确度要求的近似解. 但是这种方法并不能保证在新的*Krylov*子空间中所得到的近似解越来越靠近精确解.

Algorithm : Restarted GMRES :

- 1 计算 $r_0 = b - Ax_0$, $\beta = \| r_0 \|_2$, 及 $v_1 = \frac{r_0}{\beta}$
- 2 用Arnoldi过程生成正交基和矩阵 $\bar{H}_m$
- 3 从 v_1 开始
- 4 计算 $\min \| \beta e_1 - \bar{H}_m y \|_2$ 的最小二乘解 y_m , 并且形成 $x_m = x_0 + V_m y_m$
- 5 如果达到精度要求, 则停止计算。否则, 令 $x_0 := x_m$ 并且go to 1.

Lanczos过程的导出

A 是一个对称矩阵时, 对 $\mathcal{K}_m(A, r_0)$ 使用 $Arnoldi$ 正交化过程有:

$$H_m = V_m^T A V_m.$$

因为 $H_m^T = (V_m^T A V_m)^T = V_m^T A V_m = H_m$, 所以 H_m 是一个对称矩阵。又因为 H_m 是 $Hessenberg$ 矩阵, 所以 H_m 是对称三对角矩阵, 即其系数有下列形式:

$$h_{ij} = 0, \quad 1 \leq i < j - 1$$

$$h_{j,j+1} = h_{j+1,j}, \quad j = 1, 2, \dots, m$$

Lanczos过程的导出

在这里, 我们用 T_m 替代表示 H_m , 令

$$\alpha_j = h_{jj}, \beta_j = h_{j-1,j}$$

则

$$T_m = \begin{pmatrix} \alpha_1 & \beta_2 & & & \\ \beta_2 & \alpha_2 & \beta_3 & & \\ & \dots & & \dots & \\ & & \beta_{m-1} & \alpha_{m-1} & \beta_m \\ & & & \beta_m & \alpha_m \end{pmatrix}$$

接下来我们可以得到Lanczos算法.

Lanczos过程的导出

以 $m = 4$ 为例:

$$A(v_1, v_2, v_3, v_4) = (v_1, v_2, v_3, v_4) \begin{pmatrix} \alpha_1 & \beta_2 & & \\ \beta_2 & \alpha_2 & \beta_3 & \\ & \beta_3 & \alpha_3 & \beta_4 \\ & & \beta_4 & \alpha_4 \end{pmatrix} + \beta_5 v_5 e_4^T$$

因此有:

$$Av_1 = \alpha_1 v_1 + \beta_2 v_2, \Leftrightarrow \beta_2 v_2 = Av_1 - \alpha_1 v_1.$$

$$Av_2 = \beta_2 v_1 + \alpha_2 v_2 + \beta_3 v_3 \Leftrightarrow \beta_3 v_3 = Av_2 - \beta_2 v_1 - \alpha_2 v_2$$

$$Av_3 = \beta_3 v_2 + \alpha_3 v_3 + \beta_4 v_4 \Leftrightarrow \beta_4 v_4 = Av_3 - \beta_3 v_2 - \alpha_3 v_3$$

$$Av_4 = \beta_4 v_3 + \alpha_4 v_4 + \beta_5 v_5 \Leftrightarrow \beta_5 v_5 = Av_4 - \beta_4 v_3 - \alpha_4 v_4$$

Lanczos过程

- ① 选择初始单位向量 v_1 。令 $\beta_1 \equiv 0, v_0 \equiv 0$
- ② *For* $j = 1, 2, \dots, m$ *Do* :
- ③ $w_j := Av_j - \beta_j v_{j-1}$
- ④ $\alpha_j := (w_j, v_j)$
- ⑤ $w_j = w_j - \alpha_j v_j$
- ⑥ $\beta_{j+1} := \|w_j\|_2$. If $\beta_{j+1} = 0$ then stop
- ⑦ $v_{j+1} := w_j / \beta_{j+1}$
- ⑧ *EndDo*

Lanczos 算法

当 A 对称时,我们可以用正交残量法 (与 FOM 算法类似) 求解线性方程组 $Ax = b$ 。

给定一个初值 x_0 , 利用 $Lanczos$ 算法计算出 $\mathcal{K}_m$ 的标准正交基 $v_i (i = 1, 2, \dots, m)$ 和三对角矩阵 T_m ,

$$x_m = x_0 + V_m y_m, \quad r_m = b - A(x_0 + V_m y_m) = r_0 - AV_m y_m \perp V_m.$$

所以有:

$$0 = V_m^T (r_0 - AV_m y_m) \Leftrightarrow y_m = T_m^{-1}(\beta e_1)$$

Lanczos算法

- ❶ Computer $r_0 = b - Ax_0, \beta := \|r_0\|_2$, and $v_1 := \frac{r_0}{\beta}$
- ❷ For $j = 1, 2, \dots, m$ Do :
- ❸ $w_j = Av_j - \beta_j v_{j-1}$ (If $j = 1$ set $\beta_1 = v_0 \equiv 0$)
- ❹ $\alpha_j = (w_j, v_j)$
- ❺ $w_j = w_j - \alpha_j v_j$
- ❻ $\beta_{j+1} = \|w_j\|_2$. If $\beta_{j+1} = 0$ set $m := j$ and go to 9
- ❼ $v_{j+1} = \frac{w_j}{\beta_{j+1}}$
- ❽ EndDo
- ❾ Set $T_m = \text{tridiag}(\beta_i, \alpha_i, \beta_{i+1})$, and $V_m = [v_1, \dots, v_m]$
- ❿ Computer $y_m = T_m^{-1}(\beta e_1)$ and $x_m = x_0 + V_m y_m$

D-Lanczos算法的导出

和之前讨论过的 $Arnoldi$ 过程和 FOM 算法一样,有些结论在这里仍然是成立的.

比如,第 m 步的近似解的残量:

$$r_m = b - Ax_m = -\beta_{m+1}e_m^T y_m v_{m+1} \quad (5)$$

类似于由 IOM 可以推导出 $DIOM$ 方法, 首先先对 T_m 做 LU 分解,得到 $T_m = L_m U_m$.即

$$\begin{pmatrix} \alpha_1 & \beta_2 & & & \\ \beta_2 & \alpha_2 & \beta_3 & & \\ & \beta_3 & \alpha_3 & \beta_4 & \\ & & \beta_4 & \alpha_4 & \beta_5 \\ & & & \beta_5 & \alpha_5 \end{pmatrix} = \begin{pmatrix} 1 & & & & \\ \lambda_2 & 1 & & & \\ & \lambda_3 & 1 & & \\ & & \lambda_4 & 1 & \\ & & & \lambda_5 & 1 \end{pmatrix} \begin{pmatrix} \eta_1 & x_2 & & & \\ & \eta_2 & x_3 & & \\ & & \eta_3 & x_4 & \\ & & & \eta_4 & x_5 \\ & & & & \eta_5 \end{pmatrix}$$

$$x_2 = \beta_2 = \lambda_2 \eta_1, \quad x_3 = \beta_3 = \lambda_3 \eta_2, \quad \dots, \quad x_5 = \beta_5 = \lambda_5 \eta_4$$

$$\alpha_1 = \eta_1, \quad \alpha_2 = \lambda_2 \beta_2 + \eta_2, \quad \alpha_3 = \lambda_3 \beta_3 + \eta_3$$

D-Lanczos算法的导出

则第 m 步近似解为:

$$x_m = x_0 + V_m U_m^{-1} L_m^{-1} (\beta e_1)$$

令

$$P_m = V_m U_m^{-1}, z_m = L_m^{-1} \beta e_1$$

$$(p_1, p_2, p_3, p_4, p_5) \begin{pmatrix} \eta_1 & \beta_2 & & & \\ & \eta_2 & \beta_3 & & \\ & & \eta_3 & \beta_4 & \\ & & & \eta_4 & \beta_5 \\ & & & & \eta_5 \end{pmatrix} = (v_1, v_2, v_3, v_4, v_5)$$

$$v_1 = \eta_1 p_1, \quad v_2 = \beta_2 p_1 + \eta_2 p_2, \quad \cdots, \quad v_m = \beta_m p_{m-1} + \eta_m p_m.$$

D-Lanczos算法的导出

则

$$x_m = x_0 + P_m z_m$$

类似于 $DIOM$, 用 p_m 表示 P_m 的最后一列, 则

$$\begin{aligned} v_m &= \beta_m p_{m-1} + \eta_m p_m \\ p_m &= \eta_m^{-1} (v_m - \beta_m p_{m-1}) \end{aligned}$$

再看 T_m 的 LU 分解: 先对 T_m 做 LU 分解, 得到 $T_m = L_m U_m$. 即

$$\begin{pmatrix} \alpha_1 & \beta_2 & & & \\ \beta_2 & \alpha_2 & \beta_3 & & \\ & \beta_3 & \alpha_3 & \beta_4 & \\ & & \beta_4 & \alpha_4 & \beta_5 \\ & & & \beta_5 & \alpha_5 \end{pmatrix} = \begin{pmatrix} 1 & & & & \\ \lambda_2 & 1 & & & \\ & \lambda_3 & 1 & & \\ & & \lambda_4 & 1 & \\ & & & \lambda_5 & 1 \end{pmatrix} \begin{pmatrix} \eta_1 & \beta_2 & & & \\ & \eta_2 & \beta_3 & & \\ & & \eta_3 & \beta_4 & \\ & & & \eta_4 & \beta_5 \\ & & & & \eta_5 \end{pmatrix}$$

D-Lanczos算法的导出

由矩阵乘法知道:

$$\beta_m = \lambda_m \eta_{m-1}, \alpha_m = \lambda_m \beta_m + \eta_m$$

所以

$$\lambda_m = \frac{\beta_m}{\eta_{m-1}}, \eta_m = \alpha_m - \lambda_m \beta_m$$

因为 $z_m = L_m^{-1} \beta e_1$, 我们举例观察 z_m

$$z_4 = L_4^{-1} \beta e_1 = \begin{pmatrix} 1 & 0 & 0 & 0 \\ -\lambda_2 & 1 & 0 & 0 \\ \lambda_2 \lambda_3 & -\lambda_3 & 1 & 0 \\ -\lambda_2 \lambda_3 \lambda_4 & \lambda_3 \lambda_4 & -\lambda_4 & 1 \end{pmatrix} \begin{pmatrix} \beta \\ 0 \\ 0 \\ 0 \end{pmatrix}$$

D-Lanczos算法的导出

$$z_4 = L_4^{-1}\beta e_1 = \begin{pmatrix} 1 & 0 & 0 & 0 \\ -\lambda_2 & 1 & 0 & 0 \\ \lambda_2\lambda_3 & -\lambda_3 & 1 & 0 \\ -\lambda_2\lambda_3\lambda_4 & \lambda_3\lambda_4 & -\lambda_4 & 1 \end{pmatrix} \begin{pmatrix} \beta \\ 0 \\ 0 \\ 0 \end{pmatrix}$$

$$z_5 = L_5^{-1}\beta e_1 = \begin{pmatrix} 1 & 0 & 0 & 0 & 0 \\ -\lambda_2 & 1 & 0 & 0 & 0 \\ \lambda_2\lambda_3 & -\lambda_3 & 1 & 0 & 0 \\ -\lambda_2\lambda_3\lambda_4 & \lambda_3\lambda_4 & -\lambda_4 & 1 & 0 \\ \lambda_2\lambda_3\lambda_4\lambda_5 & -\lambda_3\lambda_4\lambda_5 & \lambda_4\lambda_5 & -\lambda_5 & 1 \end{pmatrix} \begin{pmatrix} \beta \\ 0 \\ 0 \\ 0 \\ 0 \end{pmatrix}$$

D-Lanczos算法的导出

一般地, 我们有, 令

$$z_m = \begin{bmatrix} z_{m-1} \\ \zeta_m \end{bmatrix}$$

其中 $\zeta_m = -\lambda_m \zeta_{m-1}$.

所以可以得到

$$x_m = x_{m-1} + \zeta_m p_m$$

D-Lanczos算法

- 1 Compute $r_0 = b - Ax_0$, $\zeta_1 := \beta := \|r_0\|_2$, and $v_1 := \frac{r_0}{\beta}$
- 2 Set $\lambda_1 = \beta_1 = 0, p_0 = 0$
- 3 For $m = 1, 2, \dots$, until convergence Do:
 - 4 Compute $w := Av_m - \beta_m v_{m-1}$ and $\alpha_m = (w, v_m)$
 - 5 If $m > 1$ then compute $\lambda_m = \frac{\beta_m}{\eta_{m-1}}$ and $\zeta_m = -\lambda_m \zeta_{m-1}$
 - 6 $\eta_m = \alpha_m - \lambda_m \beta_m$
 - 7 $p_m = \eta_m^{-1}(v_m - \beta_m p_{m-1})$
 - 8 $x_m = x_{m-1} + \zeta_m p_m$
 - 9 If x_m has converged then stop
 - 10 $w := w - \alpha_m v_m$
 - 11 $\beta_{m+1} = \|w\|_2, v_{m+1} = \frac{w}{\beta_{m+1}}$
- 12 EndDo

D-Lanczos算法的性质

这个算法是运用没有选主元的高斯消去法来逐步地求出三角线性方程 $T_m y_m = \beta e_1$ 的解.

*Lanczos*算法和 $D - Lanczos$ 算法在数值上是等价的,如果它们都可以执行的话,得到的是相同的近似解.

此时,用的是隐式高斯消去法求解,若用显示高斯消去法则更容易中断.

从等式(5)中我们可以看出, r_m 是 v_{m+1} 的倍数.

所以和 FOM 方法一样, r_i 是正交的.

更特殊地,当 A 对称正定时,我们用 $r_m = b - Ax_m, m = 0, 1, \dots$,表示 $Lanczos$ 算法和 $D - Lanczos$ 算法得到的残差向量, p_m 是 $D - Lanczos$ 算法中的辅助向量,即 P_m 的最后一列. 下面证明两个结论.

D-Lanczos算法的性质

定理

在D-Lanczos算法中, $r_m = \sigma_m v_{m+1}$, 这里的 σ_m 是某个标量,并且 r_i 相互正交; 向量组 p_i 形成了一个关于 A 的共轭集,即 $(Ap_i, p_j) = 0$,若 $i \neq j$.

证明: 由前面的分析可以马上得到 $r_m = \sigma_m v_{m+1}$,并且 r_i 相互正交.

要证当 $i \neq j$ 时, $(Ap_i, p_j) = 0$,即证矩阵 $P_m^T A P_m$ 是对角矩阵.

由于 $(P_m^T A P_m)^T = P_m^T A P_m$,所以矩阵 $P_m^T A P_m$ 是对称矩阵.

又因为 $P_m = V_m U_m^{-1}$

所以

$$\begin{aligned} P_m^T A P_m &= U_m^{-T} V_m^T A V_m U_m^{-1} \\ &= U_m^{-T} T_m U_m^{-1} \\ &= U_m^{-T} L_m \end{aligned}$$

D-Lanczos算法的性质

定理

在D-Lanczos算法中, $r_m = \sigma_m v_{m+1}$, 这里的 σ_m 是某个标量,并且 r_i 相互正交; 向量组 p_i 形成了一个关于 A 的共轭集,即 $(Ap_i, p_j) = 0$,若 $i \neq j$.

另外 $U_m^{-T} L_m$ 是一个下三角矩阵,
故 $P_m^T A P_m$ 是对称矩阵,同时也是下三角矩阵.
即 $P_m^T A P_m$ 是对角矩阵,得证.

共轭梯度法 (The Conjugate Gradient algorithm) 的导出

由DLanczos算法可知, x_{j+1} 可以写成:

$$x_{j+1} = x_j + \alpha_j p_j$$

这里的 p_j 是搜索方向.

所以

$$\begin{aligned} Ax_{j+1} &= Ax_j + \alpha_j Ap_j \\ b - Ax_{j+1} &= b - Ax_j - \alpha_j Ap_j \\ r_{j+1} &= r_j - \alpha_j Ap_j \end{aligned}$$

共轭梯度法 (The Conjugate Gradient algorithm) 的导出

又因为 r_j 是正交的,所以

$$\begin{aligned}(r_{j+1}, r_j) &= 0 \\(r_j - \alpha_j A p_j, r_j) &= 0 \\ \alpha_j (A p_j, r_j) &= (r_j, r_j) \\ \alpha_j &= \frac{(r_j, r_j)}{(A p_j, r_j)}\end{aligned}$$

另外 p_{j+1} 可以写成 r_{j+1} 和 p_j 的线性组合,可以得到

$$p_{j+1} = r_{j+1} + \beta_j p_j$$

这里把DLanczos方法中的 p_j 换成 p_{j+1} .所以

$$(A p_j, r_j) = (A p_j, p_j - \beta_{j-1} p_{j-1}) = (A p_j, p_j) - \beta_{j-1} (A p_j, p_{j-1}) = (A p_j, p_j)$$

共轭梯度法 (The Conjugate Gradient algorithm) 的导出

所以 α_j 也可以写成:

$$\alpha_j = \frac{(r_j, r_j)}{(Ap_j, p_j)}$$

另外由于

$$(Ap_j, p_{j+1}) = (Ap_j, r_{j+1} + \beta_j p_j) = (Ap_j, r_{j+1}) + \beta_j (Ap_j, p_j) = 0$$

所以

$$\beta_j = -\frac{(Ap_j, r_{j+1})}{(Ap_j, p_j)} \quad (6)$$

共轭梯度法 (The Conjugate Gradient algorithm) 的导出

由前面的等式

$$r_{j+1} = r_j - \alpha_j A p_j$$

可以得到

$$A p_j = -\frac{1}{\alpha_j} (r_{j+1}, r_j)$$

将上式代入式(6),可以得到

$$\beta_j = \frac{1}{\alpha_j} \frac{((r_{j+1} - r_j), r_{j+1})}{(A p_j, p_j)} = \frac{1}{\alpha_j} \frac{(r_{j+1}, r_{j+1})}{(A p_j, p_j)} = \frac{(r_{j+1}, r_{j+1})}{(r_j, r_j)}$$

共轭梯度法 (The Conjugate Gradient algorithm)

- 1 Compute $r_0 := b - Ax_0, p_0 = r_0$.
- 2 For $j = 0, 1, \dots$, until convergence Do :
- 3 $\alpha_j := \frac{(r_j, r_j)}{(Ap_j, p_j)}$
- 4 $x_{j+1} := x_j + \alpha_j p_j$
- 5 $r_{j+1} := r_j - \alpha_j Ap_j$
- 6 $\beta_j := \frac{(r_{j+1}, r_{j+1})}{(r_j, r_j)}$
- 7 $p_{j+1} := r_{j+1} + \beta_j p_j$
- 8 EndDo

注意:这里的标量 α_j 和 β_j 和Lanczos算法中的 α_j, β_j 不一样,并且这里的 p_j 是D - Lanczos算法中的 p'_j s的倍数.

关于存储,这里除了存储矩阵 A 之外,还需要存储向量 (x, p, Ap, r) ,而D - Lanczos 算法需要存储向量 (v_m, v_{m-1}, w, p, x) .

Eigenvalue estimates from the CG coefficients

我们可以从共轭梯度法的系数 α_i, β_i 得到 T_m 的元素,而三对角矩阵 T_m 与 A 的特征值有紧密的联系.比如,可以通过 T_m 的最大与最小特征值来估计 A 的最大与最小特征值.还有可以计算出 A 的条件数来估计残量范数。

下面就利用共轭梯度法的系数来推导 T_m 的形式.

令

$$T_m = \text{tridiag}[\eta_j, \delta_j, \eta_{j+1}]$$

由于

$$r_j = \|r_j\|_2 v_{j+1}$$

所以

$$\delta_{j+1} = (Av_{j+1}, v_{j+1}) = \frac{(Av_{j+1}, v_{j+1})}{(v_{j+1}, v_{j+1})} = \frac{(Ar_j, r_j)}{(r_j, r_j)}$$

Eigenvalue estimates from the CG coefficients

由于

$$r_j = p_j - \beta_{j-1}p_{j-1}$$

所以

$$(Ar_j, r_j) = (A(p_j - \beta_{j-1}p_{j-1}), p_j - \beta_{j-1}p_{j-1})$$

因为向量 p_i 关于 A 正交,

所以

$$(Ar_j, r_j) = (Ap_j, p_j) + \beta_{j-1}^2 (Ap_{j-1}, Ap_{j-1})$$

注意到当 $j = 0$ 时,

$$\beta_{j-1}p_{j-1} = 0$$

Eigenvalue estimates from the CG coefficients

当 $j > 0$ 时,得到

$$\begin{aligned}\delta_j &= \frac{(Ar_j, r_j)}{(r_j, r_j)} \\&= \frac{(Ap_j, p_j)}{(r_j, r_j)} + \beta_{j-1}^2 \frac{(Ap_{j-1}, Ap_{j-1})}{(r_j, r_j)} \\&= \frac{(Ap_j, p_j)}{(r_j, r_j)} + \beta_{j-1} \frac{(r_j, r_j)}{(r_{j-1}, r_{j-1})} \frac{(Ap_{j-1}, Ap_{j-1})}{(r_j, r_j)} \\&= \frac{1}{\alpha_j} + \frac{\beta_{j-1}}{\alpha_{j-1}}\end{aligned}$$

当 $j = 0$ 时,第二项可以省略.

Eigenvalue estimates from the CG coefficients

另外

$$\eta_{j+1} = (Av_{j+1}, v_j) = (Av_j, v_{j+1}) = \frac{|(Ar_{j-1}, r_j)|}{\|r_{j-1}\|_2 \|r_j\|_2}$$

而

$$\begin{aligned}(Ar_{j-1}, r_j) &= (A(p_{j-1} - \beta_{j-2}p_{j-2}), r_j) \\&= (Ap_{j-1}, r_j) - \beta_{j-2}(Ap_{j-2}, r_j) \\&= \frac{-1}{\alpha_{j-1}}(r_j - r_{j-1}, r_j) + \frac{\beta_{j-2}}{\alpha_{j-2}}(r_{j-1} - r_{j-2}, r_j) \\&= \frac{-1}{\alpha_{j-1}}(r_j, r_j)\end{aligned}$$

Eigenvalue estimates from the CG coefficients

因此

$$\eta_{j+1} = \frac{1}{\alpha_{j-1}} \frac{(r_j, r_j)}{\|r_{j-1}\|_2 \|r_j\|_2} = \frac{1}{\alpha_{j-1}} \frac{\|r_j\|_2}{\|r_{j-1}\|_2} = \frac{\sqrt{\beta_{j-1}}}{\alpha_{j-1}}$$

故可以通过共轭梯度的系数来得到 T_m :

$$T_m = \begin{pmatrix} \frac{1}{\alpha_0} & \frac{\sqrt{\beta_0}}{\alpha_0} & & & \\ \frac{\sqrt{\beta_0}}{\alpha_0} & \frac{1}{\alpha_1} + \frac{\beta_0}{\alpha_0} & \frac{\sqrt{\beta_1}}{\alpha_1} & & \\ & \dots & & \dots & \\ & \dots & & \dots & \\ & & \frac{\sqrt{\beta_{m-2}}}{\alpha_{m-2}} & \frac{1}{\alpha_{m-1}} + \frac{\beta_{m-2}}{\alpha_{m-2}} & \end{pmatrix}$$

共轭梯度法的收敛性分析

定理

如果 $A = I + B$, 而且 $\text{rank}(B) = r$, 则共轭梯度法至多迭代 $r + 1$ 步即可得到方程组 $Ax = b$ 的精确解。

证明：注意到 $\text{rank}(B) = r$ 蕴含着子空间

$$\text{span} \{r_0, Ar_0, \dots, A^k r_0\} = \text{span} \{r_0, Br_0, \dots, B^k r_0\}$$

的维数不会超过 $r + 1$ 。证毕。

共轭梯度法的收敛性分析

引理

设 A 的特征值为 $0 < \lambda_1 \leq \lambda_2 \leq \cdots \leq \lambda_n$, $P(t)$ 是一个 t 多项式, 则

$$\|P(A)x\|_A \leq \max_{1 \leq i \leq n} |P(\lambda_i)| \|x\|_A, \quad x \in \mathcal{R}^n.$$

证明: 设 $y_1, y_2, \cdots, y_n$ 是 A 的对应于 $\lambda_1, \lambda_2, \cdots, \lambda_n$ 的特征向量所构成的 $\mathcal{R}^n$ 的一组标准正交基, 则对任意的 $x \in \mathcal{R}^n$, 有 $x = \sum_{i=1}^n \beta_i y_i$, 从而有

$$\begin{aligned} x^T P(A) A P(A) x &= \left(\sum_{i=1}^n \beta_i P(\lambda_i) y_i \right)^T A \left(\sum_{i=1}^n \beta_i P(\lambda_i) y_i \right) \\ &= \sum_{i=1}^n \lambda_i \beta_i^2 P^2(\lambda_i) \leq \max_{1 \leq i \leq n} P^2(\lambda_i) \sum_{i=1}^n \lambda_i \beta_i^2 \end{aligned}$$

共轭梯度法的收敛性分析

证明（续）：

$$\begin{aligned}x^T P(A) A P(A) x &= \left(\sum_{i=1}^n \beta_i P(\lambda_i) y_i \right)^T A \left(\sum_{i=1}^n \beta_i P(\lambda_i) y_i \right) \\&= \sum_{i=1}^n \lambda_i \beta_i^2 P^2(\lambda_i) \leq \max_{1 \leq i \leq n} P^2(\lambda_i) \sum_{i=1}^n \lambda_i \beta_i^2 \\&= \max_{1 \leq i \leq n} P^2(\lambda_i) x^T A x.\end{aligned}$$

于是

$$\|P(A)x\|_A \leq \max_{1 \leq i \leq n} |P(\lambda_i)| \|x\|_A.$$

共轭梯度法的收敛性分析

定理

用共轭梯度法计算得到的近似解 x_k 满足

$$\|x_k - x_*\|_A = \min\{\|x - x_*\|_A : x \in x_0 + \mathcal{K}_k(A, r_0)\},$$

其中 $\|x\|_A = \sqrt{(x^T A x)}$, x_* 是 $Ax = b$ 的精确解。

证明：共轭梯度法使用的是正交残量法，即

$$b - Ax_k = r_k = A(x_* - x_k) \perp x_0 + \mathcal{K}_k(A, r_0)$$

如果定义内积 $(\cdot, \cdot)_A = (A\cdot, \cdot)$ ，则

$$x_* - x_k \perp_A x_0 + \mathcal{K}_k(A, r_0)$$

证毕。

共轭梯度法的收敛性分析

定理

用共轭梯度法求得的 x_k 有如下的误差估计:

$$\|x_k - x_*\|_A \leq 2 \left(\frac{\sqrt{\kappa_2} - 1}{\sqrt{\kappa_2} + 1} \right)^k \|x_0 - x_*\|_A,$$

其中 $\kappa_2 = \kappa_2(A) = \|A\|_2 \|A^{-1}\|_2$.

证明: 对任意的 $x \in x_0 + \mathcal{K}_k(A, r_0)$, 有

$$\begin{aligned} x_* - x &= x_* - x_0 + a_{k1}r_0 + a_{k2}Ar_0 + \cdots + a_{kk}A^{k-1}r_0 \\ &= A^{-1}(Ax_* - Ax_0 + a_{k1}Ar_0 + a_{k2}A^2r_0 + \cdots + a_{kk}A^k r_0) \\ &= A^{-1}(r_0 + a_{k1}Ar_0 + a_{k2}A^2r_0 + \cdots + a_{kk}A^k r_0) \\ &= A^{-1}P_k(A)r_0, \end{aligned}$$

共轭梯度法的收敛性分析

证明（续）：

其中 $P_k(\lambda) = 1 + \sum_{j=1}^k a_{kj} \lambda^j$ 。令 $\mathcal{P}_k$ 为所有满足 $P_k(0) = 1$ 且次数不超过 k 的实系数多项式全体，则由前面的引理和定理有

$$\begin{aligned}\|x_* - x_k\|_A &= \min \{ \|x - x_*\|_A : x \in x_0 + \mathcal{K}_k(A, r_0) \} \\ &= \min_{P_k \in \mathcal{P}_k} \|A^{-1} P_k(A) r_0\|_A = \min_{P_k \in \mathcal{P}_k} \|P_k(A) A^{-1} r_0\|_A \\ &\leq \min_{P_k \in \mathcal{P}_k} \max_{1 \leq i \leq n} |P_k(\lambda_i)| \|A^{-1} r_0\|_A \\ &\leq \min_{P_k \in \mathcal{P}_k} \max_{a \leq \lambda \leq b} |P_k(\lambda)| \|x_* - x_0\|_A\end{aligned}$$

其中 $0 < a = \lambda_1 \leq \dots \leq \lambda_n = b$ 是 A 的特征值。由 Chebyshev 多项式逼近定理可知，最优化问题

$$\min_{P_k \in \mathcal{P}_k} \max_{a \leq \lambda \leq b} |P_k(\lambda)|$$

有唯一的解

共轭梯度法的收敛性分析

优化问题

$$\min_{P_k \in \mathcal{P}_k} \max_{a \leq \lambda \leq b} |P_k(\lambda)|$$

有唯一的解

$$\tilde{P}_k(\lambda) = \frac{T_k\left(\frac{b+a-2\lambda}{b-a}\right)}{T_k\left(\frac{b+a}{b-a}\right)},$$

其中 $T_k(z)$ 是 k 次Chebyshev多项式。由Chebyshev多项式的性质知

$$\max_{a \leq \lambda \leq b} |\tilde{P}_k| = \frac{1}{T_k\left(\frac{b+a}{b-a}\right)} \leq 2 \left(\frac{\sqrt{\kappa_2} - 1}{\sqrt{\kappa_2} + 1} \right)^k,$$

于是, 我们有 $\|x_k - x_*\|_A \leq 2 \left(\frac{\sqrt{\kappa_2} - 1}{\sqrt{\kappa_2} + 1} \right)^k \|x_0 - x_*\|_A$,