



第一讲 散点图与回归

袁洪松

内容概要:

散点图与回归, 均值函数与方差函数

课本章节:

Weisberg Chapter 1

1 回归的基本概念

回归 (regression) 是研究变量之间关系的方法。




图 1: 回归中的自变量与因变量.

其中, 输入的变量 X 称为自变量 (independent variable, input variable, 或 predictor), 输出的变量称为因变量 (dependent variable, output variable, 或 predicted variable)。 Y 通常带有随机性。

X 与 Y 均可作为向量或者标量:

- 若 X 为标量, 则称为simple regression.
- 若 X 为向量, 则称为multiple regression.
- 若 Y 为标量, 则称为univariate regression.
- 若 Y 为向量, 则称为multivariate regression.

2 散点图

假设 X, Y 均为标量。用 $(x_i, y_i), i = 1, \dots, n$ 表示从整体 (X, Y) 中观测到的样本。散点图 (scatterplot) 就是把 $(x_i, y_i), i = 1, \dots, n$ 画在二维坐标平面上。




图 2: 散点图示例.

例 (Weisberg Section 1.1, Inheritance of Height) 见教材.

例 (Weisberg Section 1.1, Forbes's Data) 见教材.

例 (Weisberg Section 1.1, Length at Age for Smallmouth Bass) 见教材.

例 (Weisberg Section 1.1, Predicting the Weather) 见教材.

例 (Weisberg Section 1.1, Turkey Growth) 见教材.

例 (Weisberg Section 1.6, Fuel Consumption) 见教材.

3 均值与方差函数

研究随机变量 Y 随着 X 的变化,不妨研究 Y 的分布随 X 的变化,而这可以由研究 Y 的均值(期望值)随 X 的变化开始。

均值函数 (mean function) 定义为

$$E(Y | X = x).$$

(含义是“在给定 $X = x$ 时 Y 的条件期望”,它为 x 的一个函数。)

例如, 设 X 与 Y 均为标量, 在某些问题中我们可以认为

$$E(Y | X = x) = \beta_0^* + \beta_1^* x,$$

即均值函数为一条直线。 β_0^* 与 β_1^* 为此均值函数的两个参数(parameters), 其中 β_0^* 称为截距(intercept), β_1^* 称为斜率(slope)。参数的真实值通常未知, 需要利用样本来估计。

例 (Weisberg Section 1.2, Inheritance of Height) 观察散点图, 可以假设均值函数为

$$E(\text{dheight} | \text{mheight} = x) = \beta_0^* + \beta_1^* x.$$

例 (Weisberg Section 1.2, Length at Age for Smallmouth Bass) 虚线代表未指定任何具体函数形式的估计, 由于无参数, 所以叫无参(nonparametric)估计的均值函数, 有时也称为平滑子(smoother)。实线代表线性均值函数的估计。实线与虚线结合的很紧密, 表明两种估计方法差距不大。

例 (Weisberg Section 1.2, Predicting the Weather) 可以假设一个线性均值函数

$$E(\text{late} | \text{early} = x) = \beta_0^* + \beta_1^* x.$$

但此线性关系是否成立, 需要检验

$$H_0 : \beta_1^* = 0 \text{ v.s. } H_1 : \beta_1^* \neq 0.$$

例 (Weisberg Section 1.2, Turkey Growth) 可以假设一个非线性均值函数

$$E(\text{gain} | \text{dose} = x) = \beta_0^* + \beta_1^* (1 - e^{-\beta_2^* x}).$$

方差函数 (variance function) 定义为

$$\text{Var}(Y | X = x).$$

(含义是“在给定 $X = x$ 时 Y 的条件方差”, 它也为 x 的一个函数。)

通常假设方差函数为一个常数: $\text{Var}(Y \mid X = x) = \sigma_*^2$, 但 σ_*^2 为未知量。

思考: 什么样的分布完全由均值与方差决定?